概率论与数理统计

喵喵喵

2020 年 9 月 21 日

目录

1 概率论的基本概念

1.1 随机实验

1.2 样本空间、随机事件

将随机试验 E 的所有可能结果组成的集合称为 E 的 **样本空间**，记为 S，样本空间的元素，即 E 的每个结果，称为 **样本点**

称试验 E 的样本空间 S 的子集为 E **随机事件**，简称 **事件**。在每次试验中，当且仅当这一子集中的一个样本点出现时，称这一 **事件发生**

由一个样本点组成的单点集称为 **基本事件**

样本空间 S 包含所有的样本点，他是 S 自身的子集，在每次试验中它总是出现，S 称为 **必然事件**，空集 $\emptyset$ 称为 **不可能事件**

设试验 E 的样本空间为 S，而 $A, B, A_k \subseteq S$

1. 若 $A \subset B$，则称事件 B 包含事件 A，事件 A 的发生必导致事件 B 发生
   若 $A \subset B, B \subset A$ 即 $A = B$，则称事件 A 与事件 B **相等**
2. 事件 $A \cup B = \{x \mid x \in A \text{ or } x \in B\}$ 称为事件 A 与事件 B 的 **和事件**，当且仅当 A, B 中至少由一个发生时，事件 $A \cup B$ 发生
3. 事件 $A \cap B = \{x \mid x \in A \text{ and } x \in B\}$ 称为事件 A 与事件 B 的 **积事件**，也记作 AB
   称 $\bigcap_{k=1}^{\infty} A_k$ 为可列个事件 $A_1, A_2, ...$ 的积事件
4. 事件 $A - B = \{x \mid x \in A \text{ and } x \notin B\}$ 称为事件 A 与事件 B 的 **差事件**
5. 若 $A \cap B = \emptyset$，则称事件 A 与事件 B **互不相容**或 **互斥**的
6. 若 $A \cup B = S, A \cap B = \emptyset$，则称事件 A 与事件 B 互为 **逆事件**，又称事件 A 与事件 B 互为 **对立事件**

1.3 频率与概率

Definition 1.1. 在相同的条件下，进行了 n 次试验，在这 n 次试验中，事件 A 发生次数 n_A 称为事件 A 发生的 **频数**，比值 n_A/n 称为事件 A 发生的 **频率**，并记成 $f_n(A)$

基本性质

1. $0 \le f_n(A) \le 1$
2. $f_n(S) = 1$
3. 若 $A_1, \dots, A_k$ 是两两互不相容的事件，则

$$f_n(A_1 \cup \dots \cup A_k) = f_n(A_1) + \dots + f_n(A_k)$$

Definition 1.2. 设 E 是随机试验，S 是它的样本空间，对于 E 的每一事件 A 赋予一个实数，记为 $P(A)$，称为事件 A 的 **概率**，如果集合函数 $P(\cdot)$ 满足下列条件

1. **非负性**：对于每一个事件 A, 有 $P(A) \ge 0$
2. **规范性**：对于必然事件，有 $P(A) = 1$
3. **可列可加性**：设 $A_1, A_2, \dots$ 是两两互不相容事件，有

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

Proposition 1.3. $P(\emptyset) = 0$

证明. 令 $A_n = \emptyset$，则 $\bigcup_{n=1}^{\infty} A_n = \emptyset$，且 $A_i A_j = \emptyset$，由可列可加性

$$P(\emptyset) = P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n) = \sum_{n=1}^{\infty} P(\emptyset)$$

由概率的非负性，$P(\emptyset) = 0$ □

Proposition 1.4 (有限可加性). *若 $A_1, \dots, A_n$ 是两两互不相容的事件，则有*

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + \dots + P(A_n)$$

证明. 令 $A_{n+1} = A_{n+2} = \dots = \emptyset$，即有 $A_i A_j = \emptyset$

$$\begin{aligned}
&P(A_1 \cup A_2 \cup \dots \cup A_n) \\
&\quad = P(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} P(A_k) \\
&\quad = \sum_{k=1}^{\infty} P(A_k) + 0 = P(A_1) + \dots + P(A_n)
\end{aligned}$$

□

Proposition 1.5. 设 A, B 是两个事件，若 $A \subset B$, 则有

$$P(B-A) = P(B) - P(A)$$
$$P(B) \geq P(A)$$

证明. $B = A \cup (B-A)$ □

Proposition 1.6. 对于任一事件 A

$$P(A) \leq 1$$

证明. $P(A) \leq P(S) = 1$ □

Proposition 1.7 (逆事件的概率)**.** 对于任一事件 A, 有

$$P(\overline{A}) = 1 - P(A)$$

证明. $P(S) = P(A \cup \overline{A})$ □

Proposition 1.8 (加法公式)**.** 对于任一两事件 A, B 有

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

证明. $A \cup B = A \cup (B - AB)$

$$P(A \cup B) = P(A) + P(B - AB) = P(A) + P(B) - P(AB)$$

□

可推广到

$$P(A_1 \cup A_2 \cup \cdots \cup A_n) = \sum_{i=1}^{n} P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j)$$
$$+ \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) + \cdots + (-1)^{n-1} P(A_1 \ldots A_n)$$

1.4 等可能概型（古典概型）

等可能概型（古典概型）

1. 试验的样本空间只包含有限个元素
2. 试验中每个基本事件发生的可能性相同

设试验的样本空间为 $S = \{e_1, \dots, e_n\}$，由于在试验中每个基本事件发生的可能性相同，即

$$P(\{e_1\}) = \dots = P(\{e_n\})$$

又由于基本事件两两互不相容，于是

$$\begin{aligned}1 = P(S) &= P(\{e_1\} \cup \dots \cup \{e_n\}) \\ &= P(\{e_1\}) + \dots + P(\{e_n\}) \\ &= nP(\{e_i\})\end{aligned}$$

于是

$$P(\{e_i\}) = \frac{1}{n}$$

若事件 A 包含 k 个基本 i 事件，即 $A = \{e_{i_1}\} \cup \dots \cup \{e_{i_k}\}$，则有

$$P(A) = \sum_{j=1}^{n} P(\{e_{i_j}\}) = \frac{k}{n}$$

Example 1.1. 设有 N 件产品，其中有 D 件次品，今从中任取 n 件，文其中恰有 $k(k \le D)$ 件次品的概率

$$p = \frac{\binom{D}{k}\binom{N-D}{n-k}}{\binom{N}{n}}$$

Example 1.2. 袋中有 a 只白球，b 只红球，k 个人依次在袋中取一只球，求第 i 人取到白球（记为事件 B）的概率（$k \le a+b$）

共有 A_{a+b}^{k} 个基本事件，事件 B 发生时，第 i 人取的应是白球，有 a 中取法，剩余 $k-1$ 只球有 A_{a+b-1}^{k-1} 种取法，则

$$P(B) = \frac{a \cdot A_{a+b-1}^{k-1}}{A_{a+b}^{k}} = \frac{a}{a+b}$$

1.5 条件概率

Definition 1.9. 设 A, B 是两个事件，且 $P(A) > 0$，称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 B 发生的 **条件概率**

条件概率 $P(\cdot|A)$ 符合

1. **非负性**：对于每一事件 B，有 $P(B|A) \geq 0$
2. **规范性**：对于必然事件 S，有 $P(S|A) = 1$
3. **可列可加性**：设 $B_1, B_2, \ldots$ 是两两互不相容的事件，则有

$$P(\bigcup_{i=1}^{\infty} B_i|A) = \sum_{i=1}^{\infty} P(B_i|A)$$

Theorem 1.10 (乘法定理)**.** 设 $P(A) > 0$，则有

$$P(AB) = P(B|A)P(A)$$

一般地，设 $A_1, \ldots, A_n$ 为 n 个事件，$n \geq 2$，且 $P(A_1 \ldots A_{n-1}) > 0$，则有

$$P(A_1 \ldots A_n) = P(A_n|A_1 \ldots A_{n-1})P(A_{n-1}|A_1 \ldots A_{n-2}) \ldots P(A_2|A_1)P(A_1)$$

Example 1.3. 设袋中装有 r 只红球，t 只白球，每次自袋中任取一只球，观察其颜色再放回，并再放入 a 只与所取出的那只球同色的球，若在袋中连续取球四次，试求第一、二次取到红球且第三、四次取到白球的概率

以 A_i 表示事件“第 i 次取到红球”，则

$$\begin{aligned} P(A_1A_2\overline{A_3}\,\overline{A_4}) &= P(\overline{A_4}|A_1A_2\overline{A_3})P(\overline{A_3}|A_1A_2)P(A_2|A_1)P(A_1) \\ &= \frac{t+a}{r+t+3a} \cdot \frac{t}{r+t+2a} \cdot \frac{r+a}{r+t+a} \cdot \frac{r}{r+t} \end{aligned}$$

Definition 1.11. 设 S 为试验 E 的样本空间，$B_1, \ldots, B_n$ 为 E 的一组事件，若

1. $B_iB_j = \emptyset, i \neq j, i, j = 1, 2, \ldots, n$
2. $B_1 \cup B_2 \cup \cdots \cup B_n = S$

则称 $B_1,\dots,B_n$ 为样本空间 S 的一个 **划分**

Theorem 1.12. 设试验 E 的样本空间为 S，A 为 E 的事件，$B_1,\dots,B_n$ 为 S 的一个划分，且 $P(B_i)>0$，则

$$P(A)=P(A|B_1)P(B_1)+\cdots+P(A|B_n)P(B_n)$$

称为 **全概率公式**

证明.

$$A=AS=A(B_1\cup\cdots\cup B_n)=AB_1\cup\cdots\cup AB_n$$

□

Theorem 1.13. 设试验 E 的样本空间 S，A 为 E 的事件，$B_1,\dots,B_n$ 为 S 的一个划分，且 $P(A)>0,P(B_i)>0$，则

$$P(B_i|A)=\frac{P(A|B_i)P(B_i)}{\sum_{j=1}^{n}P(A|B_j)P(B_j)}$$

称为 **贝叶斯公式**

特别的，取 $n=2$，则

$$P(A)=P(A|B)P(B)+P(A|\overline{B})P(\overline{B})$$
$$P(B|A)=\frac{AB}{A}=\frac{P(A|B)P(B)}{P(A|B)P(B)+P(A|\overline{B})P(\overline{B})}$$

Example 1.4. 患肺癌的概率约为 0.1%, 在人群中有 20% 是吸烟者，他们患肺癌的概率约为 0.4%，求不吸者患肺癌的概率

以 C 记事件 “患肺癌”，以 A 记事件 “吸烟”，则 $P(C)=0.001,P(A)=0.2,P(C|A)=0.004$，由全概率公式

$$P(C)=P(C|A)P(A)+P(C|\overline{A})P(\overline{A})$$

因此

$$P(C|\overline{A})=0.00025$$

1.6 独立性

Definition 1.14. 设 A, B 是两事件，如果满足

$$P(AB) = P(A)P(B)$$

则称事件 A, B **相互独立**，简称 A, B **独立**

Theorem 1.15. 设 A, B 是两事件，且 $P(A) > 0$，若 A, B 相互独立，则 $P(B|A) = P(B)$

Theorem 1.16. 若事件 A, B 相互独立，则 A 与 $\overline{B}$，$\overline{A}$ 与 B，$\overline{A}$ 与 B 也相互独立

Definition 1.17. 设 A, B, C 是三个事件，满足

$$\begin{cases} P(AB) = P(A)P(B) \\ P(BC) = P(B)P(C) \\ P(AC) = P(A)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases}$$

则称事件 A, B, C **相互独立**

一般地，设 $A_1, \ldots, A_n$，如果对于 q 其中任意 $2, 3, \ldots, n$ 个事件的积事件的概率，都等于各事件概率之积，则称事件 $A_1, \ldots, A_n$ **相互独立**

Example 1.5. 要验收一批（100）件乐器，验收方案如下：自该批乐器中随机地取 3 件测试（相互独立），如果 3 件中至少有一件在测试中被认为音色不纯，则这批乐器被拒绝接收。设一件音色不纯的乐器经测试查出其音色不纯的概率为 0.95，而一件音色纯的乐器被误认为不纯的概率为 0.01，已知 100 中有 4 件音色不纯，试问这批乐器被接收的概率是多少

设以 H_i 表示 3 件中恰有 i 件不纯，A 表示这批批乐器被接收，则

$$P(A|H_0) = 0.99^3, P(A|H_1) = 0.99^2 \times 0.05$$
$$P(A|H_2) = 0.99 \times 0.05^2, P(A|H_3) = 0.05^3$$

而

$$P(H_0)=\frac{\binom{96}{3}}{\binom{100}{3}},P(H_1)=\frac{\binom{4}{1}\binom{96}{2}}{\binom{100}{3}}$$
$$P(H_2)=\frac{\binom{4}{2}\binom{96}{1}}{\binom{100}{3}},P(H_3)=\frac{\binom{4}{3}}{\binom{100}{3}}$$

故

$$P(A)=\sum P(A|H_i)P(H_i)$$

2 随机变量及其分布

2.1 随机变量

Definition 2.1. 设随机试验的样本空间为 $S=\{e\},X=X(e)$ 是定义在样本空间 S 上的实值单值函数，称 $X=X(e)$ 为随机变量

2.2 离散型随机变量及其分布律

设离散型随机变量 X 所有可能取的值为 $x_k(k=1,2,\dots)$，X 取各个可能值的概率，即事件 $\{X=x_k\}$ 的概率，为

$$P\{X=x_k\}=p_k,k=1,2,... \tag{2.2.1}$$

由概率的定义,p_k 满足如下两个条件

1. $p_k\geq 0,k=1,2,...$
2. $\sum_{k=1}^{\infty}p_k=1$

我们称 (2.2.1) 为离散型随机变量 X 的 **分布律**，分布律也可以用表格表示

X	x_1	x_2	...	x_n	...
p_k	p_1	p_2	...	p_n	...

2.2.1 （0-1）分布

设随机变量 X 只可能取 0 与 1 两个值，它的分布律是

$$P\{X=k\}=p^k(1-p)^{1-k}, k=0,1 \quad (0<p<1)$$

则称 X 服从以 p 为参数的（0-1）分布或两点分布

2.2.2 伯努利试验、二项分布

设试验 E 只有两个可能结果：A 及 $\overline{A}$, 则称 E 为 **伯努利试验**。设 $P(A)=p(0<p<1)$，此时 $P(\overline{A}=1-p)$。将 E 独立重复地进行 n 次，则称这一串重复的独立试验为 n **重伯努利试验**

以 X 表示 n 重伯努利事件 A 发生的次数，X 是一个随机变量。记 $q=1-p$，即有

$$P\{X=k\}=\binom{n}{k}p^kq^{1-k}$$

注意到 $\binom{n}{k}p^kq^{1-k}$ 刚好是 $(p+q)^n$ 的展开式中出现 p^k 的那一项，我们称随机变量 X 服从参数 n,p 的 **二项分布**，并记为 $X\sim b(n,p)$

2.2.3 泊松分布

设随机变量 X 所有可能的值为 $0,1,2,...$，而各个值的概率为

$$P\{X=k\}=\frac{\lambda^k e^{-\lambda}}{k!}$$

其中 $\lambda>0$ 是常数，则称 X 服从参数 λ 的 **泊松分布**，记为 $X\sim\pi(\lambda)$

易知 $P\{X=k\}\geq 0$，$k=0,1,2,...$，且有

$$\sum_{k=0}^{\infty}P\{X=k\}=\sum_{k=0}^{\infty}\frac{\lambda^k e^{-\lambda}}{k!}=e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=e^{-\lambda}e^{\lambda}=1$$

Theorem 2.2 (泊松定理)**.** 设 $\lambda>0$ 是一个常数，n 是任意正整数，设 $np_n=\lambda$，则对于任意固定的非负整数 k，有

$$\lim_{n\to\infty}\binom{n}{k}p_n^k(1-p_n)^{n-k}=\frac{\lambda^k e^{-\lambda}}{k!}$$

证明. 设 $p_n = \frac{\lambda}{n}$，有

$$\begin{aligned}\binom{n}{k} p_n^k (1-p_k)^{n-k} &= \frac{n(n-1)\dots(n-k+1)}{k!}(\frac{\lambda}{n})^k(1-\frac{\lambda}{n})^{n-k} \\ &= \frac{\lambda^k}{k!}[(1-\frac{1}{n})\dots(1-\frac{k-1}{n})](1-\frac{\lambda}{n})^n(1-\frac{\lambda}{n})^{-k}\end{aligned}$$

当 $n \to \infty$ 时 $(1-\frac{\lambda}{n})^n \to e^{-\lambda}$，故有

$$\lim_{n\to\infty} \binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

□

也就是说以 n, p 为参数的二项分布的概率值可以由参数为 $\lambda = np$ 的泊松分布的概率值近似

2.3 随机变量的分布函数

Definition 2.3. 设 X 是一个随机变量，x 是任意实数，函数

$$F(x) = P\{X \leq x\}, -\infty < x < \infty$$

称为 X 的 **分布函数**

对于任意实数 $x_1, x_2 (x_1 < x_2)$，有

$$\begin{aligned}P\{x_1 < X \leq x_2\} &= P\{X \leq x_2\} - P\{X \leq x_1\} \\ &= F(x_2) - F(x_1)\end{aligned}$$

分布函数 $F(x)$ 具有以下的基本性质

1. $F(x)$ 是一个不减函数
2. $0 \leq F(x) \leq 1$，且

$$F(-\infty) = \lim_{x\to-\infty} F(x) = 0$$

$$F(\infty) = \lim_{x\to\infty} F(x) = 1$$

3. $F(x+0) = F(x)$

2.4 连续型随机变量及其概率密度

如果对于随机变量 X 的分布函数 $F(x)$，存在非负函数 $f(x)$ 使对于任意实数 x 有

$$F(x) = \int_{-\infty}^{x} f(t)dt$$

则称 X 为 **连续型随机变量**，其中函数 $f(x)$ 称为 X 的 **概率密度函数**，简称 **概率密度**

概率密度 $f(x)$ 具有以下性质

1. $f(x) \geq 0$
2. $\int_{-\infty}^{\infty} f(x)dx = 1$
3. 对于任意实数 $x_1, x_2(x_1 \leq x_2)$，

$$P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx$$

4. 若 $f(x)$ 在点 x 处连续，则有 $F'(x) = f(x)$

2.4.1 均匀分布

若连续型随机变量 X 有概率密度

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \end{cases}$$

则称 X 在区间 (a, b) 上服从 **均匀分布**，记为 $X \sim U(a, b)$。分布函数

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x < b \\ 1 & x \geq b \end{cases}$$

2.4.2 指数分布

若连续型随机变量 X 的概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta}e^{-x/\theta} & x > 0 \\ 0 & \end{cases}$$

其中 $\theta > 0$ 为常数，则称 X 服从参数 θ 的 **指数分布**

$$F(x) = \begin{cases} 1 - e^{-x/\theta} & x > 0 \\ 0 \end{cases}$$

对于任意 $s, t > 0$，有

$$P\{X > s + t | X > s\} = P\{X > t\}$$

事实上

$$\begin{aligned} P\{X > s + t | X > s\} &= \frac{P\{(X > s + t) \cap (X > s)\}}{P\{X > s\}} \\ &= \frac{P\{X > s + t\}}{P\{X > s\}} = \frac{1 - F(s + t)}{1 - F(s)} \\ &= e^{-t/\theta} = P\{X > t\} \end{aligned}$$

这个性质称为无记忆性

2.4.3 正态分布

若连续型随机变量 X 的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

其中 $\mu, \sigma(\sigma > 0)$ 为常数，则称 X 服从参数为 \μ,σ 的 **正态分布**或 **高斯**分布，记为 $X \sim N(\mu, \sigma^2)$

令 $(x - \mu)/\sigma = t$, 记 $I = \int_{-\infty}^{\infty} e^{-t^2/2} dt$, 则有 $I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(t^2+u^2)/2} dt du$, 利用极坐标得

$$I^2 = \int_0^{2\pi} \int_0^{\infty} r e^{-r^2/2} dr d\theta = 2\pi$$

$f(x)$ 有以下性质

1. 曲线关于 $x = \mu$ 对称
2. 当 $x = \mu$ 时取得最大值

$$f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$$

特别的，当 $\mu=0,\sigma=1$ 时称随机变量 X 服从 **标准正态分布**，其概率密度和分布函数分别用 $\varphi(x),\Phi(x)$ 表示，即

$$\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-t^2/2}$$
$$\Phi(x)=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{x}e^{-t^2/2}dt$$

易知

$$\Phi(-x)=1-\Phi(x)$$

Lemma 2.4. 若 $X\sim N(\mu,\sigma^2)$，则 $Z=\frac{X-\mu}{\sigma}\sim N(0,1)$

于是，若 $X\sim N(\mu,\sigma^2)$，则

$$F(x)=P\{X\leq x\}=P\{\frac{X-\mu}{\sigma}\leq\frac{x-\mu}{\sigma}\}=\Phi(\frac{x-\mu}{\sigma})$$

2.5 随机变量的函数的分布

Example 2.1. 设随机变量 X 具有概率密度 $f_X(x),-\infty<x<\infty$, 求 $Y=X^2$ 的概率密度

分别记 X,Y 的分布函数为 $F_X(x),F_Y(y)$，当 $y>0$ 时

$$\begin{aligned}F_Y(y)&=P\{Y\leq y\}=\{X^2\leq y\}\\&=P\{-\sqrt{y}\leq X\leq\sqrt{y}\}\\&=F_X(\sqrt{y})-F_X(-\sqrt{y})\end{aligned}$$

因此

$$f_Y(y)=\begin{cases}\frac{1}{2\sqrt{y}}[f_X(\sqrt{y}+f_X(-\sqrt{y}))] & y>0\\0 & y\leq 0\end{cases}$$

Theorem 2.5. 设随机变量 X 具有概率密度 $f_X(x),-\infty<x<\infty$，又设函数 $g(x)$ 处处可导且恒有 $g'(x)>0$（或恒有 $g'(x)<0$），则 $Y=g(x)$ 是连续型随机变量，其概率密度为

$$f_Y(y)=\begin{cases}f_X[h(y)]|h'(y)| & \alpha<y<\beta\\0\end{cases}$$

其中 $\alpha = \min\{g(-\infty), g(\infty)\}, \beta = \max\{g(-\infty), g(\infty)\}$，$h(y)$ 是 $g(x)$ 的反函数

Proposition 2.6. 设随机变量 $X \sim N(\mu, \sigma^2)$，试证明 X 的线性函数 $Y = aX + b(a \neq 0)$ 也服从正态分布

证明. X 的概率密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

由 $Y = aX + b$

$$x = \frac{y-b}{a}, h'(y) = \frac{1}{a}$$

因此

$$\begin{aligned} f_Y(y) &= \frac{1}{|a|} f_X(\frac{y-b}{a}), -\infty < y < \infty \\ &= \frac{1}{|a|\sigma\sqrt{2\pi}} e^{-\frac{(\frac{y-b}{a}-\mu)^2}{2(a\sigma)^2}} \end{aligned}$$

即有 $Y = aX + B \sim N(a\mu + b, (a\sigma)^2)$ □

3 多维随机变量及其分布

3.1 二维随机变量

设 E 是一个随机试验,它的样本空间是 $S = \{e\}$,设 $X = X(e), Y = Y(e)$ 是定义在 S 上的随机变量，它们构成的一个向量 (X, Y) 叫做 **二维随机向量** 或 **二维随机变量**

Definition 3.1. 设 (X, Y) 是二维随机变量，对于任意实数 x, y，二元函数

$$F(x, y) = P\{(X \leq x) \cap (Y \leq y)\} (\text{written as } P\{X \leq x, Y \leq y\})$$

称为二维随机变量的 **分布函数**, 或称为随机变量 X, Y 的 **联合分布函数**

分布函数 $F(x, y)$ 具有以下性质

1. $F(x,y)$ 是变量 x,y 的不减函数
2. $0 \le F(x,y) \le 1$，且

$$\forall y, F(-\infty, y) = 0$$
$$\forall x, F(x, -\infty) = 0$$
$$F(-\infty, -\infty) = 0, F(\infty, \infty) = 1$$

3. $F(x+0,y) = F(x,y), F(x,y+0) = F(x,y)$，即 $F(x,y)$ 关于 x 又连续，关于 y 也右连续
4. 对于任意 $(x_1,y_1),(x_2,y_2),x_1 < x_2,y_1 < y_2$，下列不等式成立

$$F(x_2,y_2) - F(x_2,y_1) + F(x_1,y_1) - F(x_1,y_2) \ge 0$$

如果二维随机变量 (X,Y) 全部可能取到的值是有限对或可列无限多对，则称 (X,Y) 是 **离散型的随机变量**

设二维离散型随机变量 (X,Y) 所有可能取的值为 $(x_i,y_j), i,j = 1,2,...$，记 $P\{X = x_i, Y = y_j\} = p_{ij}$，称为二维离散型随机变量 (X,Y) 的 **分布律**，或随机变量 X,Y 的 **联合分布律**

Y,X	x_1	...	x_i	...
y_1	p_{11}	...	p_{i1}	...
$\vdots$				
y_j	p_{1j}		p_{ij}	

对于二维随机变量 (X,Y) 的分布函数 $F(x,y)$，如果存在非负的函数 $f(x,y)$ 使对于任意 x,y 有

$$F(x,y) = \int_{-\infty}^{y} \int_{-\infty}^{x} f(u,v)dudv$$

则称 (X,Y) 是 **连续型的二维随机变量**，函数 $f(x,y)$ 称为二维随机变量的 **概率密度**，或称为随机变量 X,Y 的 **联合概率密度**

概率密度 $f(x,y)$ 具有以下性质

1. $f(x,y) \ge 0$
2. $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x,y)dxdy = 1$

3. 设 G 是 xOy 平面的区域，点 (X,Y) 落在 G 内的概率为

$$P\{(X,Y)\in G\}=\iint_G f(x,y)dxdy$$

4. 若 $f(x,y)$ 在点 (x,y) 连续，则有

$$\frac{\partial^2 F(x,y)}{\partial x\partial y}=f(x,y)$$

3.2 边缘分布

$F_X(x),F_Y(y)$ 称为二维随机变量 (X,Y) 关于 X,Y 的 **边缘分布函数**

$$F_x(x)=P\{X\le x\}=P\{X\le x,Y<\infty\}=F(x,\infty)$$

记

$$p_{i\cdot}\sum_{j=1}^{\infty}p_{ij}=P\{X=x_i\}$$
$$p_{\cdot j}\sum_{i=1}^{\infty}p_{ij}=P\{X=y_j\}$$

分别称为 $p_{i\cdot}$ 和 $p_{\cdot j}$ 为 (X,Y) 关于 X,Y 的 **边缘分布律**

$$f_X(x)=\int_{-\infty}^{\infty}f(x,y)dy$$
$$f_Y(y)=\int_{-\infty}^{\infty}f(x,y)dx$$

分别为 X,Y 的 **边缘概率密度**

Example 3.1. 设二维随机变量 (X,Y) 的概率密度

$$\begin{aligned}f(x,y)=&\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}\right.\right.\\&\left.\left.-2\rho\frac{(x-\mu_1)(x-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}\end{aligned}$$

其中 $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ 都是常数，且 $\sigma_1, \sigma_2 > 0, -1 < \rho < 1$，我们称 (X, Y) 服从参数为 $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ 的 **二维正态分布**, 记为 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 试求二维正态分布随机变量的边缘概率密度

令 $t = \frac{1}{\sqrt{1-\rho^2}}(\frac{y-\mu_2}{\sigma_2} - \rho\frac{x-\mu_1}{\sigma_1})$，则有

$$f_X(x) = \frac{1}{2\pi\sigma^1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt$$

即

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$$

3.3 条件分布

Definition 3.2. 设 (X, Y) 是二维离散型随机变量，对于固定的 j，若 $P\{Y = y_j\} > 0$，则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{\cdot j}}$$

为在 $Y = y_j$ 条件下随机变量 X 的 **条件分布律**

Definition 3.3. 设二维随机变量 (X, Y) 的概率密度为 $f(x, y)$，(X, Y) 关于 Y 的边缘概率密度为 $f_Y(y)$，若对于固定的 y，$f_Y(y) > 0$，则称 $\frac{f(x,y)}{f_Y(y)}$ 为在 $Y = y$ 的条件下 X 的 **条件概率密度**，记为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

称 $F_{X|Y}(x|y) = \int_{-\infty}^{x} f_{X|Y}(x|y)dx = \int_{-\infty}^{x} \frac{f(x,y)}{f_Y(y)}dx$ 为在 $Y = y$ 下 X 的条件分布函数

3.4 相互独立的随机变量

Definition 3.4. 设 $F(x, y)$ 及 $F_X(x), F_Y(y)$ 分别是二维随机变量 (X, Y) 的分布函数及边缘分布函数，若对于所有 x, y 有

$$\begin{aligned} P\{X \le x, Y \le y\} &= P\{X \le x\}P\{Y \le y\} \\ F(x, y) &= F_X(x)F_Y(y) \\ f(x, y) &= f_X(x)f_Y(y) \end{aligned}$$

则称 X, Y 是 **相互独立的**

下面考查二维正态随机变量 (X, Y)，它的概率密度为

$$\begin{aligned} f(x, y) =& \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{\frac{-1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}\right.\right. \\ & \left.\left. -2\rho\frac{(x-\mu_1)(x-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\} \end{aligned}$$

如果 $\rho = 0$ 则对于所有 x, y,$f(x, y) = f_X(x)f_Y(y)$。如果 X, Y 相互独立，令 $x = \mu_1, y = \mu_2$，则 $\rho = 0$

对于二维正态随机变量 (X, Y)，X, Y 相互独立的充要条件是参数 $\rho = 0$

Theorem 3.5. 设 $(X_1, \dots, X_m)$ 和 $(Y_1, \dots, Y_n)$ 相互独立，则 X_i 和 Y_j 相互独立。又若 h, g 是连续函数，则 $h(X_1, \dots, X_m)$ 和 $g(Y_1, \dots, Y_n)$ 相互独立

3.5 两个随机变量的函数的分布

3.5.1 $Z = X + Y$ 分布

设 (X, Y) 是二维连续型随机变量，它具有概率密度 $f(x, y)$，则 $Z = X + Y$ 仍为连续型随机变量，其概率密度为

$$\begin{aligned} f_{X+Y}(z) &= \int_{-\infty}^{\infty} f(z-y, y)dy \\ f_{X+Y}(z) &= \int_{-\infty}^{\infty} f(x, z-x)dx \end{aligned}$$

又设 X,Y 相互独立，则

$$f_{X+Y}(z)=\int_{-\infty}^{\infty}f_X(z-y)f_Y(y)dy$$
$$f_{X+Y}(z)=\int_{-\infty}^{\infty}f_X(x)f_Y(z-x)dx$$

称为 f_X,f_Y 的 **卷积公式**，记为 f_X*f_Y，即

$$f_X*f_Y=\int_{-\infty}^{\infty}f_X(z-y)f_Y(y)dy=\int_{-\infty}^{\infty}f_X(x)f_Y(z-x)dx$$

证明.

$$F_Z(z)=P\{Z\le z\}=\iint_{x+y\le z}f(x,y)dxdy$$

则

$$F_z(z)=\int_{-\infty}^{\infty}\left[\int_{-\infty}^{z-y}f(x,y)dx\right]dy$$
$$F_z(z)=\int_{-\infty}^{\infty}\left[\int_{-\infty}^{z}f(u-y,y)du\right]dy$$
$$F_z(z)=\int_{-\infty}^{z}\left[\int_{-\infty}^{\infty}f(u-y,y)dy\right]du$$

□

有限个相互独立的正态随机变量的线性组合仍服从正态分布

Example 3.2. 设随机变量 X,Y 相互独立，且分别服从参数为 $\alpha,\theta;\beta,\theta$ 的 Γ 分布（分别记成 $X\sim\Gamma(a,\theta),Y\sim\Gamma(\beta,\theta)$），$X,Y$ 的概率密度分别为

$$f_X(x)=\begin{cases}\frac{1}{\theta^\alpha\Gamma(\alpha)}x^{\alpha-1}e^{-x/\theta} & x>0\\ 0\end{cases},\alpha>0,\theta>0$$

$$f_Y(y)=\begin{cases}\frac{1}{\theta^\beta\Gamma(\beta)}y^{\beta-1}e^{-y/\theta} & y>0\\ 0\end{cases},\beta>0,\theta>0$$

试证明 $X+Y\sim\Gamma(\alpha+\beta,\theta)$

$$f_Z(z)=\int_{-\infty}^{\infty}f_X(x)f_Y(z-x)dx$$

仅当 $0<x<z$ 时被积函数不等于零，当 $z<0$ 时 $f_Z(z)=0$，当 $z>0$ 有

$$\begin{aligned}f_Z(z)&=\int_0^x\frac{1}{\theta^\alpha\Gamma(\alpha)}x^{\alpha-1}e^{-x/\theta}\frac{1}{\theta^\beta\Gamma(\beta)}(z-x)^{\beta-1}e^{-(z-x)/\theta}ds\\&=\frac{e^{-z/\theta}}{\theta^{\alpha+\beta}\Gamma(\alpha)\Gamma(\beta)}\int_0^z x^{\alpha-1}(z-x)^{\beta-1}dx(\text{let }x=zt)\\&=\frac{z^{\alpha+\beta-1}e^{-z/\theta}}{\theta^{\alpha+\beta}\Gamma(\alpha)\Gamma(\beta)}\int_0^1 t^{\alpha-1}(1-t)^{\beta-1}dt\\&=Az^{\alpha+\beta-1}e^{-z/\theta}\end{aligned}$$

其中 $A=\frac{1}{\theta^{\alpha+\beta}\Gamma(\alpha)\Gamma(\beta)}\int_0^1 t^{\alpha-1}(1-t)^{\beta-1}dt$ 由概率密度的性质得

$$\begin{aligned}1&=\int_{-\infty}^{\infty}f_Z(z)dz=\int_0^{\infty}Az^{\alpha+\beta-1}e^{-z/\theta}dz\\&=A\theta^{\alpha+\beta}\int_0^{\infty}(z/\theta)^{\alpha+\beta-1}e^{-z/\theta}d(z/\theta)\\&=A\theta^{\alpha+\beta}\Gamma(\alpha+\beta)\end{aligned}$$

3.5.2 $Z=\frac{Y}{X},Z=XY$ 的分布

$$f_{Y/X}(z)=\int_{-\infty}^{\infty}|x|f(x,xz)dx$$
$$f_{XY}(z)=\int_{-\infty}^{\infty}\frac{1}{|x|}f(x,\frac{z}{x})dx$$

3.5.3 $M=\mathbf{max}\{X,Y\},N=\mathbf{min}\{X,Y\}$ 的分布

对于 n 个相互独立的随机变量

$$F_{\max}(z)=[F(z)]^n$$
$$F_{\min}(z)=1-[1-F(z)]^n$$

4 随机变量的数字特征

4.1 数学期望

Definition 4.1. 设离散型随机变量 X 的分布律

$$P\{X=x_k\}=p_k, k=1,2,...$$

若级数

$$\sum_{k=1}^{\infty} x_k p_k$$

绝对收敛，则称级数 $\sum_{k=1}^{\infty} x_k p_k$ 的和为随机变量 X 的 **数学期望**，记为 $E(X)$

若连续型随机变量 X 的概率密度为 $f(x)$，若积分

$$\int_{-\infty}^{\infty} x f(x) dx$$

绝对收敛，则称积分 $\int_{-\infty}^{\infty} x f(x) dx$ 的值为随机变量 X 设 **数学期望**，记为 $E(X)$

Example 4.1. 设 $X \sim \pi(\lambda)$，求 $E(X)$

$$E(X)=\sum_{k=0}^{\infty} k\frac{\lambda^k e^{-\lambda}}{k!}=\lambda e^{-\lambda}\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!}=\lambda e^{-\lambda}e^{\lambda}=\lambda$$

Theorem 4.2. 设 Y 是随机变量 X 的函数：$Y=g(X)$（g 是连续函数）

1. 如果 X 是离散型随机变量，它的分布律为 $P\{X=x_k\}=p_k$，若 $\sum_{k=1}^{\infty} g(x_k)p_k$ 绝对收敛，则

$$E(Y)=E[g(X)]=\sum_{k=1}^{\infty} g(x_k)p_k$$

2. 如果 X 是连续型随机变量，它的概率密度为 $f(x)$，若 $\int_{-\infty}^{\infty} g(x)f(x)dx$ 绝对收敛，则

$$E(Y)=E[g(X)]=\int_{-\infty}^{\infty} g(x)f(x)dx$$

数学期望的几个重要性质

1. 设 C 是常数，则 $E(C)=C$
2. 设 X 是一个随机变量，C 是常数，则有

$$E(CX)=CE(X)$$

3. 设 X,Y 是两个随机变量，则有

$$E(X+Y)=E(X)+E(Y)$$

4. 设 X,Y 是相互独立的随机变量，则有

$$E(XY)=E(X)E(Y)$$

4.2 方差

Definition 4.3. 设 X 是一个随机变量，若 $E\{[X-E(X)]^2\}$ 存在，则称 $E\{[X-E(X)]^2\}$ 为 X 的 **方差**，记为 $D(X)$ 或 $Var(X)$

$\sqrt{D(X)}$，记为 $\sigma(X)$，称为 **标准差**或 **均方差**

Theorem 4.4. $D(X)=E(X^2)-[E(X)]^2$

Example 4.2. 设随机变量 X 具有数学期望 $E(X)=\mu$，方差 $D(X)=\sigma^2\neq 0$，记

$$X^*=\frac{X-\mu}{\sigma}$$

则

$$E(E^*)=0$$
$$D(X^*)=1$$

即 $X^*=\frac{X-\mu}{\sigma}$ 的数学期望为 0，方差为 1，X^* 称为 X 的 **标准化变量**

Example 4.3. 设随机变量 $X\sim\pi(\lambda)$，求 $D(X)$

随机变量 X 的分布律为

$$P\{X=k\}=\frac{\lambda^k e^{-\lambda}}{k!}$$

因为 $E(X)=\lambda$，而

$$\begin{aligned} E(X^2) &= E[X(X-1)+X] = E[X(X-1)] + E(X) = \\ &= \sum_{k=0}^{\infty} k(k-1)\frac{\lambda^k e^{-\lambda}}{k!} + \lambda = \lambda^2 e^{-\lambda}\sum_{k=2}^{\infty}\frac{\lambda^{k-2}}{(k-2)!} + \lambda \\ &= \lambda^2 + \lambda \end{aligned}$$

所以方差

$$D(X) = \lambda$$

Example 4.4. 设随机变量 $X \sim U(a,b)$，求 $D(X)$

$E(X)=\frac{a+b}{2}$，方差为

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 \\ &= \int_a^b x^2 \frac{1}{b-a}dx - (\frac{a+b}{2})^2 = \frac{(b-a)^2}{12} \end{aligned}$$

Example 4.5. 设随机变量 X 服从指数分布，其概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta}e^{-x/\theta} & x > 0 \\ 0 & x \le 0 \end{cases}$$

其中 $\theta > 0$，求 $E(X), D(X)$

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} xf(x) = \theta \\ E(X^2) &= 2\theta^2 \\ D(X) &= \theta^2 \end{aligned}$$

方差的几个性质

1. 设 C 是常数，则 $D(C)=0$
2. 设 X 是随机变量，C 是常数，则有

$$D(CX) = C^2 D(X), D(X+C) = D(X)$$

3. 设 X,Y 是两个随机变量，则有

$$D(X+Y)=D(X)+D(Y)+2E\{(X-E(X))(Y-E(Y))\}$$

特别地，若 X,Y 相互独立，则

$$D(X+Y)=D(X)+D(Y)$$

4. $D(X)=0$ 的充要条件是 X 以概率 1 取常数 $E(X)$

Example 4.6. 设随机变量 $X\sim b(n,p)$，求 $E(X),D(X)$

引入随机变量

$$X_k=\begin{cases}1 & A \text{ happens at k}th\\ 0 & \end{cases}$$

易知 $X=X_1+\cdots+X_n$。因为 $E(X_k)=p,D(X_k)=p(1-p)$，故

$$E(X)=E(\sum_{k=1}^{n}X_k)=np$$
$$D(X)=D(\sum_{k=1}^{n}X_k)=np(1-p)$$

Example 4.7. 设随机变量 $X\sim N(\mu,\sigma^2)$，求 $E(X),D(X)$

先求标准正态变量

$$Z=\frac{X-\mu}{\sigma}$$

的数学期望和方差，Z 的概率密度为

$$\varphi(t)=\frac{1}{\sqrt{2\pi}}e^{-t^2/2}$$

于是

$$E(Z)=0$$
$$D(Z)=E(Z^2)=1$$

因 $X=\mu+\sigma Z$，即得

$$E(X)=E(\mu+\sigma Z)=\mu$$
$$D(X)=\sigma^2$$

推广得

$$C_1X_1 + \cdots + C_nX_n \sim N(\sum_{i=1}^{n} C_i\mu_i, \sum_{i=1}^{n} C_i^2\sigma_i^2)$$

Definition 4.5 (切比雪夫不等式)**.** 设随机变量 X 具有数学期望 $E(X) = \mu$，方差 $D(X) = \sigma^2$, 则对于任意正数 ϵ ，不等式

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

4.3 协方差及相关系数

Definition 4.6. $E\{[E - E(X)][Y - E(Y)]\}$ 称为随机变量 X 与 Y 的 **协方差**，记为 $Cov(X, Y)$，

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

称为随机变量 X 与 Y 的 **相关系数**

有

$$D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$$
$$Cov(X, Y) = E(XY) - E(X)E(Y)$$

协方差有以下性质

1. $Cov(aX, bY) = abCov(X, Y)$
2. $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

考虑以 X 的线性函数 $a + bX$ 来近似表示 Y，我们以均方误差

$$\begin{aligned} e &= E[(Y - (a + bX))^2] \\ &= E(Y^2) + b^2E(X^2) + a^2 - 2bE(XY) + 2abE(X) - 2aE(Y) \end{aligned}$$

来衡量以 $a + bX$ 近似表达 Y 的好坏程度。将 e 分别关于 a, b 求偏到，得

$$\begin{cases} \frac{\partial e}{\partial a} = 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial e}{\partial b} = 2bE(X^2) - 2E(XY) + 2aE(X) = 0 \end{cases}$$

解得

$$b_0 = \frac{Cov(X,Y)}{D(X)}$$

$$a_0 = E(Y) - b_0 E(X)$$

代入得

$$\min_{a,b} E\{[Y-(a+bX)]^2\} = (1-\rho_{xy}^2)D(Y)$$

Theorem 4.7. *1.* $\left|\rho_{xy}\right| \leq 1$

2. $\left|\rho_{xy}\right| = 1$ 的充要条件是存在 a, b 使得

$$P\{Y = a + bX\} = 1$$

当 $\rho_{xy} = 0$ 时，称 X 和 Y 不相关

Example 4.8. 设 (X,Y) 服从二维正态分布，求 X,Y 的相关系数

$\rho_{xy} = \rho$

4.4 矩、协方差矩阵

Definition 4.8. 设 X,Y 是随机变量，若

$$E(X^k), k = 1, 2, ...$$

存在，称它为 X 的 k **阶原点矩**，简称 k **阶矩**

若

$$E\{[E-E(X)]^k\}, k = 2, 3, ...$$

存在，称它为 X 的 k **阶中心矩**

若

$$E(X^kY^l), k, l = 1, 2, ...$$

存在，称它为 X,Y 的 $k+l$ **阶混合矩**

若

$$E\{[E-E(X)]^k[Y-E(Y)]^l\}, k, l = 1, 2, ...$$

存在，称它为 X,Y 的 $k+l$ **阶混合中心矩**

5 大数定律及中心极限定理

5.1 大数定律

Theorem 5.1 (弱大数定理（辛钦大数定理）). 设 $X_1, X_2, \ldots$ 是相互独立，服从同一分布的随机变量序列，且具有数学期望 $E(X_k) = \mu$，作前 n 个变量的算术平均 $\frac{1}{n}\sum_{k=1}^{n} X_k$，则对于任意 $\epsilon > 0$，有

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right| < \epsilon\right\} = 1$$

对于独立同分布且具有均值 μ 的随机变量 $X_1, \ldots, X_n$，当 n 很大时它们的算术平均 $\frac{1}{n}\sum_{k=1}^{n} X_k$ 很可能接近 μ

设 $Y_1, \ldots, Y_n, \ldots$ 是一个随机变量序列，a 是一个常数，若对于任意正数 ϵ，有

$$\lim_{n\to\infty} P\{|Y_n - a| < \epsilon\} = 1$$

则称序列 $Y_1, \ldots, Y_n, \ldots$ **依概率收敛于** a，记为

$$Y_n \xrightarrow{P} a$$

设 $X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b$，又设函数 $g(x, y)$ 在点 (a, b) 连续，则

$$g(X_n, Y_n) \xrightarrow{P} g(a, b)$$

这样上述定理可叙述为

Theorem 5.2 (弱大数定理（辛钦大数定理）). 设随机变量 $X_1, \ldots, X_n, \ldots$ 相互独立，服从同一分布且具有数学期望 $E(X_k) = \mu$，则序列 $\overline{X} = \frac{1}{n}\sum_{k=1}^{n} X_k$ 一概率收敛于 μ，即 $\overline{X} \xrightarrow{P} \mu$

Theorem 5.3 (伯努利大数定理). 设 f_A 是 n 次独立重复试验中事件 A 发生的次数，p 是事件 A 在每次试验中发生的概率，则对于任意正数 $\epsilon > 0$，有

$$\lim_{n\to\infty} P\left\{\left|\frac{f_A}{n} - p\right| < \epsilon\right\} = 1$$

或

$$\lim_{n\to\infty} P\left\{\left|\frac{f_A}{n} - p\right| \geq \epsilon\right\} = 0$$

5.2 中心极限定理

Theorem 5.4 (独立同分布的中心极限定理). 设随机变量 $X_1, \dots, X_n, \dots$ 相互独立, 服从同一分布, 且具有数学期望和方差: $E(X_k) = \mu, D(X_k) = \sigma^2 > 0$, 则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意 x 满足

$$\begin{aligned}\lim_{n\to\infty} F_n(x) &= \lim_{n\to\infty} P\left\{\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \le x\right\}\\ &= \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)\end{aligned}$$

因此当 n 充分大时，有

$$\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$

或

$$\overline{X} \sim N(\mu, \sigma^2/n)$$

Theorem 5.5 (李雅普诺夫定理). 设随机变量 $X_1, \dots, X_n, \dots$ 相互独立，它们具有数学期望和方差

$$E(X_k) = \mu_k, D(X_k) = \sigma_k^2 > 0$$

记

$$B_n^2 = \sum_{k=1}^n \sigma_k^2$$

若存在正数 δ 使得当 $n \to \infty$ 时

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{\left|X_k - \mu_k\right|^{2+\delta}\} \to 0$$

则随机变量之和 $\sum_{k=1}^{n} X_k$ 的标准化变量

$$Z_n = \frac{\sum_{k=1}^{n} X_k - E(\sum_{k=1}^{n} X_k)}{\sqrt{D(\sum_{k=1}^{n} X_k)}} = \frac{\sum_{k=1}^{n} X_k - \sum_{k=1}^{n} \mu_k}{B_n}$$

的分布函数 $F_n(x)$ 对于任意 x 满足

$$\begin{aligned}\lim_{n\to\infty} F_n(x) &= \lim_{n\to\infty} P\left\{\frac{\sum_{k=1}^{n} X_k - \sum_{k=1}^{n} \mu_k}{B_n} \le x\right\} \\ &= \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)\end{aligned}$$

定理表明，在定理的条件下，随机变量

$$Z_n = \frac{\sum_{k=1}^{n} X_k - \sum_{k=1}^{n} \mu_k}{B_n}$$

当 n 很大时，近似服从正态分布 $N(0,1)$

Theorem 5.6 (棣莫弗-拉普拉斯定理)**.** 设随机变量 η_n 服从参数为 n,p 的二项分布，则对于任意 x 有

$$\lim_{n\to\infty} P\left\{\frac{\eta_n - np}{\sqrt{np(1-p)}} \le x\right\} = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

6 样本及抽样分布

6.1 随机样本

我们将试验的全部可能的观察值称为 **总体**, 每一个可能观察值称为 **个体**，总体中所包含的个体的个数称为总体的 **容量**，容量为有限的称为 **有限总体**，容量为无限的称为 **无限总体**

Definition 6.1. 设 X 是具有分布函数 F 的随机变量，若 $X_1, \dots, X_n$ 是具有同一分布函数 F 的、相互独立的随机变量，则称 $X_1, \dots, X_n$ 为从分布函数 F 得到的 **容 量为** n **的简单随机样本**，简称为 **样本**，它们的观察值 $x_1, \dots, x_n$ 称为 **样本值**, 又称为 X 的 n 个 **独立的观察值**

6.2 抽样分布

Definition 6.2. 设 $X_1, \dots, X_n$ 是来自总体 X 的一个样本 $g(X_1, \dots, X_n)$ 是 $X_1, \dots, X_n$ 的函数，若 g 中不含未知参数，则称 $g(X_1, \dots, X_n)$ 是一 **统计量**

$g(x_1, \dots, x_n)$ 是 $g(X_1, \dots, X_n)$ 的观察值

定义

样本平均值

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

样本方差

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{1}{n-1}(\sum_{i=1}^{n} X_i^2 - n\overline{X}^2)$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2}$$

样本 k 阶（原点）矩

$$A_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k, k = 1, 2, \dots$$

样本 k 阶中心矩

$$B_k = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^k, k = 2, 3, \dots$$

若总体 X 的 k 阶矩 $E(X^k) = \mu_k$ 存在，则当 $n \to \infty$ 时，$A_k \xrightarrow{P} \mu_k$，这时因为 $X_1, \dots, X_n$ 独立且与 X 同分布，所以 $X_1^k, \dots, X_n^k$ 独立且与 X_k 同分布，故有

$$E(X_1^k) = \dots = E(X_n^k) = \mu_k$$

从而由辛钦大数定理

$$A_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k \xrightarrow{P} \mu_k$$

进而由依概率收敛的序列的性质知道

$$g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k)$$

6.2.1 χ^2 分布

设 $X_1,\dots,X_n$ 是来自总体 $N(0,1)$ 的样本，则称统计量

$$\chi^2 = X_1^2 + \cdots + X_n^2$$

服从自由度为 n 的 χ^2 **分布**，记为 $\chi^2 \sim \chi^2(n)$

$\chi^2(n)$ 分布的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{n/2-1} e^{-y/2} & y > 0 \\ 0 \end{cases}$$

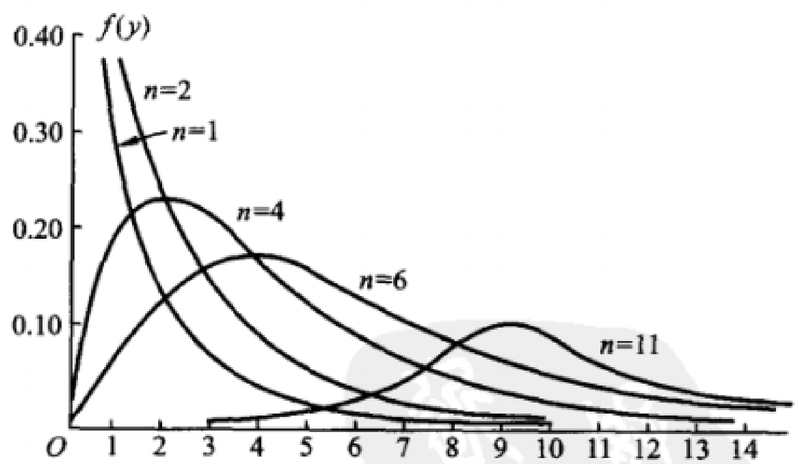

图 6—6

由 2.1 及 3.2 知 $\chi^2(1)$ 服从 $\Gamma(0.5,2)$ 分布。现 $X_i \sim N(0,1)$ 由定义 $X_i^2 \sim \chi^2(1)$，即 $X_i^2 \sim \Gamma(0.5,2)$，因此

$$\chi^2 = \sum_{i=1}^{n} X_i^2 \sim \Gamma(\frac{n}{2},2)$$

χ^2 **分布的可加性**设 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且 χ_1^2,χ_2^2 相互独立，则有

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1+n_2)$$

χ^2 **分布的数学期望和方差**若 $\chi^2 \sim \chi^2(n)$，则有

$$E(\chi^2) = n, D(\chi_2) = 2n$$

χ^2 **分布的分位点**对于给定的正数 α ，$0 < \alpha < 1$ 称满足条件

$$P\{\chi^2 > \chi^2_\alpha(n)\} = \int_{\chi^n_\alpha}^{\infty} f(y)dy = \alpha$$

的点 $\chi^n_\alpha(n)$ 为 $\chi^2(n)$ 分布的上 α 分位点

6.2.2 t 分布

设 $X \sim N(0,1), Y \sim \chi^2(n)$，且 X, Y 相互独立，则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t **分布**，记为 $t \sim t(n)$

t 分布又称 **学生式（Student）分布**，$t(n)$ 分布的概率密度函数为

$$h(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n}\Gamma(n/2)}(1+\frac{t^2}{n})^{-(n+1)/2}, -\infty < t < \infty$$

$$\lim_{n\to\infty} h(t) = \frac{1}{\sqrt{2\pi}}e^{-t^2/2}$$

6.2.3 F 分布

设 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$，且 U, V 相互独立，则称随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度 (n_1, n_2) 的 F **分布**，记为 $F \sim F(n_1, n_2)$

由定义得

$$\frac{1}{F} \sim F(n_2, n_1)$$

F 分布的上 α 分位点有如下性质

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$$

6.3 正态总体的样本均值与样本方差的分布

设总体 X 的均值为 μ，方差为 σ^2，$X_1,\ldots,X_n$ 是来自 X 的一个样本，$\overline{X},S^2$ 分别是样本均值和样本方差，则

$$E(\overline{X})=\mu,\quad D(\overline{X})=\sigma^2/n$$

而

$$\begin{aligned}E(S^2)&=E\left[\frac{1}{n-1}(\sum_{i=1}^{n}X_i^2-n\overline{X}^2)\right]=\frac{1}{n-1}\left[\sum_{i=1}^{n}E(X_i^2)-nE(\overline{X}^2)\right]\\&=\frac{1}{n-1}\left[\sum_{i=1}^{n}(\sigma^2+\mu^2)-n(\sigma^2/n+\mu^2)\right]=\sigma^2\end{aligned}$$

即

$$E(S^2)=\sigma^2$$

进而，设 $X\sim N(\mu,\sigma^2)$，则 $\overline{X}$ 也服从正态分布，则

Theorem 6.3. 设 $X_1,\ldots,X_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，$\overline{X}$ 是样本均值，则有

1. $\overline{X}\sim N(\mu,\sigma^2/n)$
2. $\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$
3. $\overline{X}$ 与 S^2 相互独立
4. $\frac{\overline{X}}{S/\sqrt{n}}\sim t(n-1)$

Theorem 6.4. 设 $X_1,\ldots,X_{n_1},Y_1,\ldots,Y_{n_2}$ 分别是来自正态总体 $N(\mu_1,\sigma_1^2)$ 和 $N(\mu_2,\sigma_2^2)$ 的样本,且这两个样本相互独立,设 $\overline{X}=\frac{1}{n_1}\sum_{i=1}^{n_1}X_i,\overline{Y}=\frac{1}{n_2}\sum_{i=1}^{n_2}Y_i$ 为别是两样本的均值，S_1^2,S_2^2 分别是两样本的样本方差，则有

1. $\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2}\sim F(n_1-1,n_2-1)$
2. 当 $\sigma_1^2=\sigma_2^2=\sigma^2$ 时

$$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)$$

其中 $S_w^2=\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2},S_w=\sqrt{S_w^2}$

7 参数估计

7.1 点估计

7.1.1 矩估计法

设 X 为连续型随机变量，其概率密度函数为 $f(x;\theta_1,\dots,\theta_k)$，或 X 为离散型随机变量，其分布律为 $P\{X=x\}=p(x;\theta_1,\dots,\theta_k)$，其中 $\theta_1,\dots,\theta_k$ 为待估计参数，$X_1,\dots,X_n$ 是来自 X 的样本，假设总体 X 的前 k 阶矩

$$
\begin{aligned}
\mu_l &= E(X^l) = \int_{-\infty}^{\infty} x^l f(x;\theta_1,\dots,\theta_k)dx \quad \text{or} \\
\mu_l &= E(X^l) = \sum_{x\in R_X} x^l p(x;\theta_1,\dots,\theta_k)
\end{aligned}
$$

其中 R_X 是 X 的取值范围，基于样本矩

$$A_l = \frac{1}{n}\sum_{i=1}^{n} X_i^l$$

依概率收敛于相应的总体矩 μ_l, 样本矩的连续函数依概率收敛于相应的总体矩的连续函数，我们就用样本矩作为相应的总体矩的估计量，而以样本矩的连续函数作为相应的总体矩的连续函数的估计量，这种估计方法称为 **矩估计法**。具体做法如下，设

$$
\begin{cases}
\mu_1 = \mu_1(\theta_1,\dots,\theta_k) \\
\mu_2 = \mu_2(\theta_1,\dots,\theta_k) \\
\vdots \\
\mu_k = \mu_k(\theta_1,\dots,\theta_k)
\end{cases}
$$

这是一个包含 k 个未知参数 $\theta_1,\dots,\theta_k$ 的联立方程组，可解出

$$
\begin{cases}
\theta_1 = \theta_1(\mu_1,\dots,\mu_k) \\
\theta_2 = \theta_2(\mu_1,\dots,\mu_k) \\
\vdots \\
\theta_k = \theta_k(\mu_1,\dots,\mu_k)
\end{cases}
$$

以 A_i 分别代替上式中的 μ_i，就以

$$\hat{\theta}_i = \theta_i(A_1, \dots, A_k)$$

分别作为 θ_i 的估计量，这种估计量称为 **矩估计量**，矩估计量的观察值称为 **矩估计值**

Example 7.1. 设总体 X 在 $[a, b]$ 上服从均匀分布，a, b 未知，$X_1, \dots, X_n$ 是来自 X 的样本，试求 a, b 的矩估计量

$$\begin{aligned}
\mu_1 &= E(X) = (a+b)/2 \\
\mu_2 &= E(X^2) = D(X) + [E(X)]^2 = (b-a)^2/12 + (a+b)^2/4
\end{aligned}$$

解得

$$a = \mu_1 - \sqrt{3(\mu_2 - \mu_1^2)}, b = \mu_1 + \sqrt{3(\mu_2 - \mu_1^2)}$$

e 分别以 A_1, A_2 代替 μ_1, μ_2

Example 7.2. 设总体 X 的均值 μ 及方差 σ^2 都存在，且有 $\sigma^2 > 0$，但 μ, σ^2 均未知，又设 $X_1, \dots, X_n$ 是来自 X 的样本，试求 μ, σ^2 的矩估计量

$$\begin{cases}
\mu_1 = E(X) = \mu \\
\mu_2 = E(X^2) = \sigma^2 + \mu^2
\end{cases}$$

解得

$$\begin{cases}
\mu = \mu_1 \\
\sigma^2 = \mu_2 - \mu_1^2
\end{cases}$$

因此

$$\begin{aligned}
\hat{\mu} &= A_1 = \overline{X} \\
\hat{\sigma}^2 &= A_2 - A_1^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 - \overline{X}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2
\end{aligned}$$

7.1.2 最大似然估计法

若总体 X 属于离散型，其分布律 $P\{X=x\}=p(x;\theta),\theta\in\Theta$ 的形式已知，θ 为待沽参数，Θ 是 θ 可能取值的范围，设 $X_1,\dots,X_n$ 是来自 X 的样本，则 $X_1,\dots,X_n$ 的联合分布

$$\prod_{i=1}^{n}p(x_1;\theta)$$

又设 $x_1,\dots,x_n$ 是相应于 $X_1,\dots,X_n$ 的样本值，则事件 $\{X_1=x_1,\dots,X_n=x_n\}$ 发生的概率为

$$L(\theta)=L(x_1,\dots,x_n;\theta)=\prod_{i=1}^{n}p(x_i;\theta),\theta\in\Theta$$

$L(\theta)$ 称为样本的 **似然函数**。取 $\hat{\theta}$ 使

$$L(x_1,\dots,x_n;\hat{\theta})=\max_{\theta\in\Theta}L(x_1,\dots,x_n;\theta)$$

这样得到的 $\hat{\theta}$ 与样本值 $x_1,\dots,x_n$ 有关，常记为 $\hat{\theta}(x_1,\dots,x_n)$, 称为参数 θ 的 **最大似然估计值**，而相应的统计量 $\hat{\theta}(X_1,\dots,X_n)$ 称为参数 θ 的 **最大似然估计量**

若总体 X 属连续型,其概率密度 $f(x;\theta),\theta\in\Theta$ 的形式已知,设 $X_1,\dots,X_n$ 是来自 X 的样本，它们的联合密度为

$$\prod_{i=1}^{n}f(x_i,\theta)$$

设 $x_1,\dots,x_n$ 是相应于样本 $X_1,\dots,X_n$ 的一个样本值，则随机点 $(X_1,\dots,X_n)$ 落在点 $(x_1,\dots,x_n)$ 的邻域（变长分别为 $dx_1,\dots,dx_n$ 的 n 维立方体）内的概率近似地为

$$\prod_{i=1}^{n}f(x_i;\theta)dx_i$$

因因子 $\prod_{i=1}^{n}dx_i$ 不随 θ 改变，故只需考虑函数

$$L(\theta)=L(x_1,\dots,x_n;\theta)=\prod_{i=1}^{n}f(x_i;\theta)$$

的最大值，这里 $L(\theta)$ 称为样本的 **似然函数**，若

$$L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$$

则称 $\hat{\theta}(x_1, \dots, x_n)$ 为 θ 的 **最大似然估计值**，称 $\hat{\theta}(X_1, \dots, X_n)$ 为 θ 的 **最大似然估计量**

很多时候 $p(x;\theta), f(x;\theta)$ 关于 θ 可微，因此 θ 的最大似然估计可以从方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

求得，这个方程称为 **对数似然方程**

Example 7.3. 设 $X \sim (1, p)$，$X_1, \dots, X_n$ 是来自 X 的一个样本，求参数 p 的最大 r 似然估计

设 $x_1, \dots, x_n$ 是相应于样本 $X_1, \dots, X_n$ 的一个样本值，X 的分布律为

$$P\{X = x\} = p^2 (1-p)^{1-x}, x = 0, 1$$

故

$$\begin{aligned} L(p) &= \prod_{i=1}^{n} p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \\ \ln L(p) &= (\sum_{i=1}^{n} x_i) \ln p + (n - \sum_{i=1}^{n} x_i) \ln(1-p) \\ \frac{d}{dp} \ln L(p) &= \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0 \\ \hat{p} &= \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x} \end{aligned}$$

Example 7.4. 设 $X \sim N(\mu, \sigma^2)$，μ,σ 未知，$x_1, \dots, x_n$ 是来自 X 的一个样本值，求 μ, σ^2 的最大似然估计函数

X 的概率密度函数

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2} (x - \mu^2) \right]$$

似然函数为

$$L(\mu,\sigma^2)=\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{1}{2\sigma^2}(x-\mu^2)\right]$$

$$=(2\pi)^{-n/2}(\sigma^2)^{-n/2}\exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right]$$

$$\ln L=-\frac{n}{2}\ln(2\pi)-\frac{n}{2}\ln\sigma^2-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2$$

令

$$\begin{cases}\frac{\partial}{\partial\mu}\ln L=\frac{1}{\sigma^2}(\sum_{i=1}^{n}x_i-n\mu)=0\\ \frac{\partial}{\partial\sigma^2}\ln L=-\frac{n}{2\sigma^2}+\frac{1}{2(\sigma^2)^2}\sum_{i=1}^{n}(x_i-\mu)^2=0\end{cases}$$

解得

$$\hat{\mu}=\overline{X},\quad \hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\overline{X})^2$$

Example 7.5. 设总体 X 在 $[a,b]$ 上服从均匀分布，a,b 未知，$x_1,\dots,x_n$ 是一个样本值，求 a,b 的最大似然估计函数记 $x_{(1)}=\min\{x_1,\dots,x_n\},x_{(n)}=\max\{x_1,\dots,x_n\}$，$X$ 的概率密度是

$$f(x;a,b)=\begin{cases}\frac{1}{b-a} & a\le x\le b\\ 0\end{cases}$$

似然函数为

$$L(a,b)=\begin{cases}\frac{1}{(b-a)^n} & a\le x_1,\dots,x_n\le b\\ 0\end{cases}$$

由于 $a\le x_1,\dots,x_n\le b$ 等价于 $a\le x_{(1)},x_{(n)}\le b$ 似然函数可写成

$$L(a,b)=\begin{cases}\frac{1}{(b-a)^n} & a\le x_{(1)},b\ge x_{(n)}\\ 0\end{cases}$$

于是对于满足条件 $a\le x_{(1)},b\ge x_{(n)}$ 的任意 a,b 有

$$L(a,b)=\frac{1}{(b-a)^n}\le\frac{1}{(x_{(n)}-x_{(1)})^n}$$

即 $L(a,b)$ 在 $a=x_{(1)},b=x_{(n)}$ 时取得最大值，故 a,b 的最大似然估计值为

$$\hat{a}=x_{(1)},\hat{b}=x_{(n)}$$

此外，最大似然估计具有下述性质：设 θ 的函数 $u=u(\theta),\theta\in\Theta$ 具有单值反函数 $\theta=\theta(u),u\in\mathcal{U}$，又假设 $\hat{\theta}$ 是 X 的概率分布中参数 θ 的最大似然估计，则 $\hat{u}=u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计，这一性质称为最大似然估计的**不变性**

7.2 基于截尾样本的最大似然估计

将随机抽取的 n 个产品在 $t=0$ 时投入试验直到每个产品都失效，记录每一个产品的失效时间，这样的道德样本叫完全样本。截尾寿命试验有两种：定时截尾寿命试验，假设将随机抽取的 n 个产品在 $t=0$ 投入试验，试验进行到事先规定的截尾时间 t_0 停止，如试验截止时共有 m 个产品失效，它们的失效时间分别为

$$0\le t_1\le ...\le t_m\le t_0$$

此时 m 是一个随机变量，所得的样本 $t_1,...,t_m$ 称为 **定时截尾样本**。另一种是定数截尾样本，t_m 是第 m 个产品的失效时间，所得到的样本 $t_1 ... t_m$ 称为 **定数截尾样本**

设产品的寿命分布为指数分布

$$f(t)=\begin{cases}\frac{1}{\theta}e^{-t/\theta} & t>0\\ 0 & \end{cases}$$

设有 n 个产品投入定数截尾试验。一个产品在 $(t_i,t_i+dt_i]$ 失效的概率近似地为 $f(t_i)dt_i=\frac{1}{\theta}e^{-t_i/\theta}dt_i$，其余 $n-m$ 个产品寿命超过 t_m 的概率为 $(\int_{t_m}^{\infty}\frac{1}{\theta}e^{-t/\theta}dt)^{n-m}=(e^{-t_m/\theta})^{n-m}$，故上述观察结果出现的概率近似地为

$$\begin{aligned}&\binom{n}{m}(\frac{1}{\theta}e^{-t_1/\theta}t_1)...(\frac{1}{\theta}e^{-t_m/\theta}t_m)(e^{-t_m/\theta})^{n-m}\\ &=\binom{n}{m}\frac{1}{\theta^m}e^{-\frac{1}{\theta}[t_1+\cdots+t_m+(n-m)t_m]}dt_1...dt_m\end{aligned}$$

其中 $dt_1, \dots, dt_m$ 为常数，因忽略常数不影响 θ 的最大似然估计，故可取似然函数为

$$L(\theta) = \frac{1}{\theta^m} e^{-\frac{1}{\theta}[t_1 + \cdots + t_m + (n-m)t_m]}$$

则

$$\frac{d}{d\theta} \ln L(\theta) = -\frac{m}{\theta} + \frac{1}{\theta^2}[t_1 + \cdots + t_m + (n-m)t_m] = 0$$

于是

$$\hat{\theta} = \frac{s(t_m)}{m}$$

其中 $s(t_m) = t_1 + \cdots + t_m + (n-m)t_m$ 称为总试验时间

对于截尾样本

$$0 \le t_1 \le \dots \le t_m \le t_0$$

可得

$$L(\theta) = \frac{1}{\theta^m} e^{-\frac{1}{\theta}[t_1 + \cdots + t_m + (n-m)t_0]}$$

$$\hat{\theta} = \frac{s(t_0)}{m}$$

其中 $s(t_0) = t_1 + \cdots + t_m + (n-m)t_0$

7.3 评估量的评选标准

7.3.1 无偏性

设 $X_1, \dots, X_n$ 是总体 X 的一个样本，$\theta \in \Theta$ 是包含在总体 X 的分布中的待沽参数，这里 Θ 是 θ 的取值范围

Definition 7.1. 若估计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在，且对于任意 $\theta \in \Theta$ 有

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的 **无偏估计量**

Example 7.6. 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ 存在，又设 $X_1, \dots, X_n$ 是 X 的一个样本，试证明不论总体服从什么分布，k 阶样本矩 $A_k = \frac{1}{n}\sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计

$X_1, \ldots, X_n$ 与 X 同分布，故有

$$E(X_i^k) = E(X^k) = \mu_k$$

Example 7.7. 设总体 X 服从指数分布，其概率密度为

$$f(x;\theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & x > 0 \\ 0 \end{cases}$$

其中 $\theta > 0$ 未知,又设 $X_1, \ldots, X_n$ 是来自 X 的样本,证明 $nZ = n(\min\{X_1, \ldots, X_n\})$ 是 θ 的无偏估计

$Z = \min\{X_1, \ldots, X_n\}$ 具有概率密度

$$f_{\min}(x;\theta) = \begin{cases} \frac{n}{\theta} e^{-nx/\theta} & x > 0 \\ 0 \end{cases}$$

故

$$E(Z) = \frac{\theta}{n}$$

7.3.2 有效性

Definition 7.2. 设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, \ldots, X_n), \hat{\theta}_2 = \hat{\theta}_2(X_1, \ldots, X_n)$ 都是 θ 的无偏估计量，若对于任意 $\theta \in \Theta$

$$D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$$

且至少对于某一个 $\theta \in \Theta$ 上式不等号成立，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ **有效**

7.3.3 相合性

Definition 7.3. 设 $\hat{\theta}(X_1, \ldots, X_n)$ 为参数 θ 的估计量，若对于任意 $\theta \in \Theta$，当 $n \to \infty$ 时 $\hat{\theta}(X_1, \ldots, X_n)$ 依概率收敛于 θ，则称 $\hat{\theta}$ 为 θ 的 **相合估计量**

7.4 区间估计

Definition 7.4. 设总体 X 的分布函数 $F(x;\theta)$ 含有一个未知数 $\theta \in \Theta$，对于给定值 $\alpha(0 < \alpha < 1)$ 若由来自 X 的样本 $X_1, \dots, X_n$ 确定的两个统计量 $\underline{\theta} < \bar{\theta}$ 对于任意 $\theta \in \Theta$ 满足

$$P\{\underline{\theta}(X_1, \dots, X_n) < \theta < \bar{\theta}(X_1, \dots, X_n)\} \geq 1 - \alpha$$

则称随机区间 $(\underline{\theta}, \bar{\theta})$ 是 θ 的置信水平为 $1 - \alpha$ 的 **置信区间**，$\underline{\theta}, \bar{\theta}$ 分别是双侧置信区间的 **置信下限**和 **置信下限**，$1 - \alpha$ 为 **置信水平**

Example 7.8. 设总体 $X \sim N(\mu, \sigma^2)$，σ^2 已知，μ 未知，设 $X_1, \dots, X_n$ 是来自 X 的样本，求 μ 的置信水平为 $1 - \alpha$ 的置信区间

$\overline{X}$ 是 μ 的无偏估计，且有

$$\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

因此按正态分布

$$P\{\left|\frac{\overline{X} - \mu}{\sigma / \sqrt{n}}\right| < z_{\alpha/2}\} = 1 - \alpha$$

即

$$P\{\overline{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} < \mu < \overline{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\} = 1 - \alpha$$

因此得到了 μ 的一个置信水平为 $1 - \alpha$ 的置信区间

$$\left(\overline{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \overline{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right)$$

寻求未知参数 θ 的置信区间的做法

1. 寻求一个样本 $X_1, \dots, X_n$ 和 θ 的函数 $W = W(X_1, \dots, X_n; \theta)$ 使得 W 的分布不依赖于 θ 以及其他未知参数，称具有这种性质的函数 W 为 **枢轴量**
2. 对于给定的置信水平 $1 - \alpha$ 定出两个常数 a, b，使得

$$P\{a < W(X_1, \dots, X_n; \theta) < b\} = 1 - \alpha$$

7.5 正态总体均值与方差的区间估计

7.5.1 单个总体 $N(\mu,\sigma^2)$ 的情况

设已给定置信水平为 $1-\alpha$，并设 $X_1,\dots,X_n$ 为总体 $N(\mu,\sigma^2)$ 的样本，$\overline{X},S^2$ 分别是样本均值和样本方差

1. 均值 μ 的置信区间
   (a) σ^2 为已知，得到
   $$\left(\overline{X}\pm\frac{\sigma}{\sqrt{n}}z_{\alpha/2}\right)$$
   (b) σ^2 未知，考虑 S^2 是 σ^2 的无偏估计，由定理 6.3
   $$\frac{\overline{X}-\mu}{S/\sqrt{n}}\sim t(n-1)$$
   因此得 μ 的一个置信水平为 $1-\alpha$ 的置信区间
   $$\left(\overline{X}\pm\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right)$$
2. 方差 σ^2 的置信区间 μ 未知，σ^2 的无偏估计为 S^2
   $$\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$$
   有
   $$P\left\{\chi^2_{1-\alpha/2}(n-1)<\frac{(n-1)S^2}{\sigma^2}<\chi^2_{\alpha/2}(n-1)\right\}=1-\alpha$$
   因此得到方差 σ^2 的一个置信水平为 $1-\alpha$ 的置信区间
   $$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)},\frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right)$$

7.5.2 两个总体 $N(\mu_1,\sigma_1^2),N(\mu_2,\sigma_2^2)$ 的情况

设给定置信水平 $1-\alpha$，并设 $X_1,\dots,X_{n_1}$ 是来自第一个总体的样本；$Y_1,\dots,Y_{n_2}$ 是来自第二个总体的样本，这两个样本相互独立，且设 $\overline{X},\overline{Y},S_1^2,S_2^2$ 分别是第一、二个总体的样本均值、方差

1. 两个总体均值差 $\mu_1-\mu_2$ 的置信区间

   (a) σ_1^2,σ_2^2 均为已知，则

$$\overline{X}-\overline{Y}\sim N(\mu_1-\mu_2,\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2})$$

   因此得到 $\mu_1-\mu_2$ 的一个置信水平为 $1-\alpha$ 的置信区间

$$\left(\overline{X}-\overline{Y}\pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}\right)$$

   (b) $\sigma_1^2=\sigma_2^2=\sigma^2$，但 σ^2 未知，此时由定理 6.4

$$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)$$

   可得 $\mu_1-\mu_2$ 的一个置信水平为 $1-\alpha$ 的置信区间为

$$\left(\overline{X}-\overline{Y}\pm t_{\alpha/2}(n_1+n_2-2)S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right)$$

   此处

$$S_2^2=\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2},S_w=\sqrt{S_w^2}$$

2. 两个总体方差比 σ_1^2/σ_2^2 的置信区间 μ_1,μ_2 均未知，由定理 6.4

$$\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2}\sim F(n_1-1,n_2-1)$$

   有

$$P\left\{F_{1-\alpha/2}(n_1-1,n_2-1)<\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2}<F_{\alpha/2}(n_1-1,n_2-1)\right\}=1-\alpha$$

   因此得 σ_1^2/σ_2^2 的一个置信水平为 $1-\alpha$ 的置信区间

$$\left(\frac{S_1^2}{S_2^2}\frac{1}{F_{\alpha/2}(n_1-1,n_2-1)},\frac{S_1^2}{S_2^2}\frac{1}{F_{1-\alpha/2}(n_1-1,n_2-1)}\right)$$

7.6 $(0-1)$ 分布参数的区间估计

设有一容量 $n>50$ 的大样本，它来自 $(0-1)$ 分布的总体 X,X 的分布律为

$$f(x;p)=p^x(1-p)^{1-x},x=0,1$$

其中 p 为未知参数，现在求 p 的置信水平为 $1-\alpha$ 的置信区间

已知 $(0-1)$ 分布的均值和方差分别为

$$\mu=p,\sigma^2=p(1-p)$$

设 $X_1,\dots,X_n$ 是一个样本，因样本容量 n 较大，由中心极限定理，知

$$\frac{n\overline{X}-np}{\sqrt{np(1-p)}}\sim N(0,1)$$

于是有

$$P\left\{-z_{\alpha/2}<\frac{n\overline{X}-np}{\sqrt{np(1-p)}}<z_{\alpha/2}\right\}\approx 1-\alpha$$

而不等式

$$-z_{\alpha/2}<\frac{n\overline{X}-np}{\sqrt{np(1-p)}}<z_{\alpha/2}$$

等价于

$$(n+z_{\alpha/2}^2)p^2-(2n\overline{X}+z_{\alpha/2}^2)p+n\overline{X}^2<0$$

记

$$p_1=\frac{1}{2a}(-b-\sqrt{b^2-4ac})$$
$$p_2=\frac{1}{2a}(-b+\sqrt{b^2-4ac})$$

此处 $a=n+z_{\alpha/2}^2,b=-(2n\overline{X}+z_{\alpha/2}^2),c=n\overline{X}^2$, 于是得置信区间

$$(p_1,p_2)$$

7.7 单侧置信区间

对于给定值 $\alpha(0 < \alpha < 1)$ 若由样本 $X_1, \dots, X_n$ 确定的统计量 $\underline{\theta} = \underline{\theta}(X_1, \dots, X_n)$ 对于任意 $\theta \in \Theta$ 满足

$$P\{\theta > \underline{\theta}\} \geq 1 - \alpha$$

称随机区间 $(\underline{\theta}, \infty)$ 是 θ 的置信水平为 $1-\alpha$ 的 **单侧置信区间**，$\underline{\theta}$ 称为 θ 的置信为凭为 $1-\alpha$ 的单侧置信上限

若对于正态总体 X, 若均值 μ，方差 σ^2 均未知，设 $X_1, \dots, X_n$ 是一个样本，由

$$\frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

有

$$P\{\frac{\overline{X} - \mu}{S/\sqrt{n}} < t_\alpha(n-1)\} = 1 - \alpha$$

因此得到 μ 的一个置信水平为 $1-\alpha$ 的单侧置信区间

$$\left(\overline{X} - \frac{S}{\sqrt{n}} t_\alpha(n-1), \infty\right)$$

8 假设检验

8.1 假设检验

Example 8.1. 某车间用一台包装机包装葡萄糖，袋装糖的净重是一个随机变量，它服从正态分布，当机器正常时，其均值为 0.5 kg，标准差为 0.015kg，某日开工后为检验包装机是否正常，随机地抽取它所包装的糖 9 袋，称得净重为（kg）

0.497 0.506 0.518 0.524 0.498 0.511 0.520 0.515 0.512

问机器是否正常

以 μ,σ 分别表示这一天袋装糖的净重总体 X 的均值和标准差。由于标准差比较稳定，设 $\sigma = 0.015$，于是 $X \sim N(\mu, 0.015^2)$，这里 μ 未知，问题

是根据样本值来判断 μ 是否等于 0.5。为此我们提出两个相互对立的假设

$$H_0 : \mu = \mu_0 = 0.5$$
$$H_1 : \mu \neq \mu_0$$

$\overline{X}$ 是 μ 的无偏估计，$\overline{X}$ 的观察值 $\bar{x}$ 的大小在一定程度上反映 μ 的大小。如果假设 H_0 为真，则观察值 $\bar{x}$ 与 μ_0 的偏差 $\left|\bar{x} - \mu_0\right|$ 一般不应太大

$P_{\mu_0}\{\cdot\}$ 表示参数 μ 取 μ_0 时事件的概率，$P_{\mu \in H_0}\{\cdot\}$ 表示 μ 取 H_0 规定的值时事件 $\{\cdot\}$ 的概率。我们希望

$$P\{\text{当 } H_0 \text{ 为真拒绝 } H_0\} \leq \alpha$$

由于只允许犯这类错误的概率最大为 α，因此

$$P_{\mu_0}\left\{\left|\overline{X} - \mu_0\right|\sigma/\sqrt{n} \geq k\right\} = \alpha$$

由于当 H_0 为真时，$Z = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$，因此

$$k = a_{\alpha/2}$$

因此若 Z 的观察值满足

$$|z| = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \geq k = z_{\alpha/2}$$

则拒绝 H_0，反之接受

数 α 称为 **显著水平**，统计量 $Z = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}}$ 称为 **检验统计量**

在显著水平 α 下，检验假设

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0$$

H_0 称为 **原假设**或 **零假设**，H_1 称为 **备择假设**

当检验统计量取某个区域 C 中的值时，我们拒绝原假设 H_0，则称区域 C 为 **拒绝域**，拒绝域的边界点称为 **临界点**

H_0 为真时拒绝称为第 I 类错误，H_0 不真时接收 H_0 称为第 II 类错误

只对犯第 I 类错误的概率加以控制而不考虑第 II 类错误的概率的检验称为 **显著性检验**。

$$H_0: \mu \le \mu_0, \quad H_1: \mu > \mu_0$$

称为 **右边检验**

$$H_0: \mu \ge \mu_0, \quad H_1: \mu < \mu_0$$

称为 **左边检验**。左边检验和右边检验统称为 **单边检验**

设总体 $X \sim N(\mu, \sigma^2)$，μ 未知，σ 已知，$X_1, ..., X_n$ 是来自 X 的样本，给定显著性水平 α ，求检验问题

$$H_0: \mu \le \mu_0, \quad H_1: \mu > \mu_0$$

的拒绝域

因 H_0 中的全部 μ 都比 H_1 中的 μ 要小，当 H_1 为真时，观察值 $\bar{x}$ 往往偏大，因此拒绝域的形式为

$$\bar{x} \ge k$$

则

$$\begin{aligned} P_{\mu \in H_0} \overline{X} \ge k &= P_{\mu \le \mu_0} \left\{ \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \ge \frac{k - \mu_0}{\sigma / \sqrt{n}} \right\} \\ &\le P_{\mu \le \mu_0} \left\{ \frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \ge \frac{k - \mu_0}{\sigma / \sqrt{n}} \right\} \end{aligned}$$

要控制 $P\{$当 H_0 为真拒绝 $H_0\} \le \alpha$ 只需令

$$P_{\mu \le \mu_0} \left\{ \frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \ge \frac{k - \mu_0}{\sigma / \sqrt{n}} \right\} = \alpha$$

因此 $\frac{k-\mu_0}{\sigma/\sqrt{n}} = z_\alpha, k = \mu_0 + \frac{\sigma}{sqrtnz_\alpha}$ ，即得拒绝域为

$$\bar{x} \ge \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha$$

同理得左边检验问题

$$H_0: \mu \ge \mu_0, \quad H_1: \mu < \mu_0$$

的拒绝域为

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}} \le -z_\alpha$$

8.2 正态总体均值的假设检验

8.2.1 单个总体 $N(\mu,\sigma^2)$ 均值 μ 检验

1. σ^2 已知，关于 μ 检验（Z 检验）利用统计量 $Z=\frac{\overline{X}-\mu_0}{\sigma/\sqrt{n}}$ 来确定拒绝域，称为 Z **检验法**
2. σ^2 未知，关于 μ 的检验（t 检验）设总体 $X\sim N(\mu,\sigma^2)$，其中 μ,σ^2 未知，求检验问题

$$H_0:\mu=\mu_0,\quad H:\mu\neq\mu_0$$

的拒绝域（显著性水平 α ）

设 $X_1,\ldots,X_n$ 是来自总体 X 的样本，用

$$t=\frac{\overline{X}-\mu_0}{S/\sqrt{n}}$$

作为检验统计量，当观察值 $|t|=\left|\frac{\overline{X}-\mu_0}{S/\sqrt{n}}\right|$ 过分大时就拒绝 H_0，拒绝域的形式为

$$|t|=\left|\frac{\overline{X}-\mu_0}{S/\sqrt{n}}\right|\geq k$$

当 H_0 为真时，$\frac{\overline{X}-\mu_0}{S/\sqrt{n}}\sim t(n-1)$，故由

$$P_{\mu_0}\left\{\left|\frac{\overline{X}-\mu_0}{S/\sqrt{n}}\right|\geq k\right\}=\alpha$$

得 $k=t_{\alpha/2}(n-1)$，即得拒绝域为

$$|t|=\left|\frac{\overline{X}-\mu_0}{S/\sqrt{n}}\right|\geq t_{\alpha/2}(n-1)$$

t **检验法**

8.2.2 两个正态总体均值差的检验 (t 检验)

求检验问题

$$H_0:\mu_1-\mu_2=\delta,\quad H_1:\mu_1-\mu_2\neq\delta$$

的拒绝域，取显著水平为 α 用下述 t 统计量作为检验统计量

$$t=\frac{(\overline{X}-\overline{Y})-\delta}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)$$

其中 $S_w^2=\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}$

$$P_{\mu_1-\mu_2=\delta}\left\{\left|\frac{(\bar{x}-\bar{y})-\delta}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)\right|\geq k\right\}=\alpha$$

得 $k=t_{\alpha/2}(n_1+n_2-2)$，于是拒绝域为

$$|t|=\left|\frac{(\bar{x}-\bar{y})-\delta}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)\right|\geq t_{\alpha/2}(n_1+n_2-2)$$

8.3 正态总体方差的假设检验

8.3.1 单个总体的情况

设总体 $X\sim N(\mu,\sigma^2)$，μ,σ^2 均未知，$X_1,\dots,X_n$ 是来自 X 的样本，要求检验假设（显著性水平为 α ）

$$H_0:\sigma^2=\sigma_0^2,\quad H_1:\sigma^2\neq\sigma_0^2$$

σ_0^2 为已知常数

当 H_0 为真时

$$\frac{(n-1)S^2}{\sigma_0^2}\sim\chi^2(n-1)$$

取

$$\chi^2=\frac{(n-1)S^2}{\sigma_0^2}$$

则拒绝域有以下形式

$$\frac{(n-1)s^2}{\sigma_0^2}\leq k_1\quad\text{or}\quad\frac{(n-1)s^2}{\sigma_0^2}\geq k_2$$

则

$$P_{\sigma_0^2}\left\{\left(\frac{(n-1)s^2}{\sigma_0^2}\le k_1\right)\cup\left(\frac{(n-1)s^2}{\sigma_0^2}\ge k_2\right)\right\}=\alpha$$

一般取

$$P_{\sigma_0^2}\left\{\frac{(n-1)s^2}{\sigma_0^2}\le k_1\right\}=\frac{\alpha}{2},P_{\sigma_0^2}\left\{\frac{(n-1)s^2}{\sigma_0^2}\ge k_2\right\}=\frac{\alpha}{2},$$

故 $k_1=\chi^2_{1-\alpha/2}(n-1),k_2=\chi^2_{\alpha/2}(n-1)$

下面求单边检验问题（显著性水平 α ）

$$H_0:\sigma^2\le\sigma_0^2,\quad H_1:\sigma^2>\sigma_0^2$$

的拒绝域，拒绝域的形式为

$$s^2\ge k$$

因为

$$\begin{aligned}P_{\sigma^2\le\sigma_0^2}\{S^2\ge k\}&=P_{\sigma^2\le\sigma_0^2}\left\{\frac{(n-1)S^2}{\sigma_0^2}\ge\frac{(n-1)k}{\sigma_0^2}\right\}\\&\le P_{\sigma^2\le\sigma_0^2}\left\{\frac{(n-1)S^2}{\sigma^2}\ge\frac{(n-1)k}{\sigma_0^2}\right\}\end{aligned}$$

只需令

$$P_{\sigma^2\le\sigma_0^2}\left\{\frac{(n-1)S^2}{\sigma^2}\ge\frac{(n-1)k}{\sigma_0^2}\right\}=\alpha$$

因此拒绝域

$$\chi^2=\frac{(n-1)s^2}{\sigma_0^2}\ge\chi^2_\alpha(n-1)$$

左边检验问题

$$H_0:\sigma^2\ge\sigma_0^2,\quad H_1:\sigma^2<\sigma_0^2$$

的拒绝域为

$$\chi^2=\frac{(n-1)s^2}{\sigma_0^2}\le\chi^2_{1-\alpha}(n-1)$$

以上检验法称为 χ^2 **检验法**

8.3.2 两个总体的情况

$\mu_1, \mu_2, \sigma_1^2, sigma_2^2$ 均未知，检验假设（显著性水平为 α ）

$$H_0 : \sigma_1^2 \leq \sigma_2^2, \quad H_1 : \sigma_1^2 > \sigma_2^2$$

当 H_1 为真时，观察值 $\frac{S_1^2}{S_2^2}$ 有偏大的趋势，故拒绝域有形式

$$\frac{s_1^2}{s_2^2} \geq k$$

因为

$$P_{\sigma_1^2 \leq \sigma_2^2} \left\{ \frac{S_1^2}{S_2^2} \geq k \right\} \leq P_{\sigma_1^2 \leq \sigma_2^2} \left\{ \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \geq k \right\}$$

只需令

$$P_{\sigma_1^2 \leq \sigma_2^2} \left\{ \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \geq k \right\} = \alpha$$

因此拒绝域为

$$F = \frac{s_1^2}{s_2^2} \geq F_\alpha(n_1 - 1, n_2 - 1)$$

F 检验法