

# 概率论与数理统计

喵喵喵

2020 年 9 月 21 日

## 目录

<b>1 概率论的基本概念</b>	<b>4</b>
1.1 随机实验	4
1.2 样本空间、随机事件	4
1.3 频率与概率	4
1.4 等可能概型（古典概型）	7
1.5 条件概率	8
1.6 独立性	10
<b>2 随机变量及其分布</b>	<b>11</b>
2.1 随机变量	11
2.2 离散型随机变量及其分布律	11
2.2.1 (0-1) 分布	12
2.2.2 伯努利试验、二项分布	12
2.2.3 泊松分布	12
2.3 随机变量的分布函数	13
2.4 连续型随机变量及其概率密度	14
2.4.1 均匀分布	14
2.4.2 指数分布	14
2.4.3 正态分布	15
2.5 随机变量的函数的分布	16

<b>3 多维随机变量及其分布</b>	<b>17</b>
3.1 二维随机变量	17
3.2 边缘分布	19
3.3 条件分布	20
3.4 相互独立的随机变量	21
3.5 两个随机变量的函数的分布	21
3.5.1 $Z = X + Y$ 分布	21
3.5.2 $Z = \frac{Y}{X}, Z = XY$ 的分布	23
3.5.3 $M = \max\{X, Y\}, N = \min\{X, Y\}$ 的分布	23
<b>4 随机变量的数字特征</b>	<b>24</b>
4.1 数学期望	24
4.2 方差	25
4.3 协方差及相关系数	28
4.4 矩、协方差矩阵	29
<b>5 大数定律及中心极限定理</b>	<b>30</b>
5.1 大数定律	30
5.2 中心极限定理	31
<b>6 样本及抽样分布</b>	<b>32</b>
6.1 随机样本	32
6.2 抽样分布	33
6.2.1 $\chi^2$ 分布	34
6.2.2 $t$ 分布	35
6.2.3 $F$ 分布	35
6.3 正态总体的样本均值与样本方差的分布	36
<b>7 参数估计</b>	<b>37</b>
7.1 点估计	37
7.1.1 矩估计法	37
7.1.2 最大似然估计法	39

7.2	基于截尾样本的最大似然估计 . . . . .	42
7.3	评估量的评选标准 . . . . .	43
7.3.1	无偏性 . . . . .	43
7.3.2	有效性 . . . . .	44
7.3.3	相合性 . . . . .	44
7.4	区间估计 . . . . .	45
7.5	正态总体均值与方差的区间估计 . . . . .	46
7.5.1	单个总体 $N(\mu, \sigma^2)$ 的情况 . . . . .	46
7.5.2	两个总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 的情况 . . . . .	46
7.6	$(0 - 1)$ 分布参数的区间估计 . . . . .	48
7.7	单侧置信区间 . . . . .	49
<b>8</b>	<b>假设检验</b>	<b>49</b>
8.1	假设检验 . . . . .	49
8.2	正态总体均值的假设检验 . . . . .	52

# 1 概率论的基本概念

## 1.1 随机实验

## 1.2 样本空间、随机事件

将随机试验  $E$  的所有可能结果组成的集合称为  $E$  的 **样本空间**，记为  $S$ ，样本空间的元素，即  $E$  的每个结果，称为 **样本点**

称试验  $E$  的样本空间  $S$  的子集为  $E$  **随机事件**，简称 **事件**。在每次试验中，当且仅当这一子集中的一个样本点出现时，称这一 **事件发生**

由一个样本点组成的单点集称为 **基本事件**

样本空间  $S$  包含所有的样本点，他是  $S$  自身的子集，在每次试验中它总是出现， $S$  称为 **必然事件**，空集  $\emptyset$  称为 **不可能事件**

设试验  $E$  的样本空间为  $S$ ，而  $A, B, A_k \subseteq S$

1. 若  $A \subset B$ ，则称事件  $B$  包含事件  $A$ ，事件  $A$  的发生必导致事件  $B$  发生  
若  $A \subset B, B \subset A$  即  $A = B$ ，则称事件  $A$  与事件  $B$  **相等**
2. 事件  $A \cup B = \{x \mid x \in A \text{ or } x \in B\}$  称为事件  $A$  与事件  $B$  的 **和事件**，当且仅当  $A, B$  中至少由一个发生时，事件  $A \cup B$  发生
3. 事件  $A \cap B = \{x \mid x \in A \text{ and } x \in B\}$  称为事件  $A$  与事件  $B$  的 **积事件**，也记作  $AB$

称  $\bigcap_{k=1}^{\infty} A_k$  为可列个事件  $A_1, A_2, \dots$  的积事件

4. 事件  $A - B = \{x \mid x \in A \text{ and } x \notin B\}$  称为事件  $A$  与事件  $B$  的 **差事件**
5. 若  $A \cap B = \emptyset$ ，则称事件  $A$  与事件  $B$  **互不相容**或 **互斥**的
6. 若  $A \cup B = S, A \cap B = \emptyset$ ，则称事件  $A$  与事件  $B$  互为 **逆事件**，又称事件  $A$  与事件  $B$  互为 **对立事件**

## 1.3 频率与概率

**Definition 1.1.** 在相同的条件下，进行了  $n$  次试验，在这  $n$  次试验中，事件  $A$  发生次数  $n_A$  称为事件  $A$  发生的 **频数**，比值  $n_A/n$  称为事件  $A$  发生的 **频率**，并记成  $f_n(A)$

基本性质

1.  $0 \leq f_n(A) \leq 1$
2.  $f_n(S) = 1$
3. 若  $A_1, \dots, A_k$  是两两互不相容的事件, 则

$$f_n(A_1 \cup \dots \cup A_k) = f_n(A_1) + \dots + f_n(A_k)$$

**Definition 1.2.** 设  $E$  是随机试验,  $S$  是它的样本空间, 对于  $E$  的每一事件  $A$  赋予一个实数, 记为  $P(A)$ , 称为事件  $A$  的 **概率**, 如果集合函数  $P(\cdot)$  满足下列条件

1. **非负性**: 对于每一个事件  $A$ , 有  $P(A) \geq 0$
2. **规范性**: 对于必然事件, 有  $P(A) = 1$
3. **可列可加性**: 设  $A_1, A_2, \dots$  是两两互不相容事件, 有

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

**Proposition 1.3.**  $P(\emptyset) = 0$

证明. 令  $A_n = \emptyset$ , 则  $\bigcup_{n=1}^{\infty} A_n = \emptyset$ , 且  $A_i A_j = \emptyset$ , 由可列可加性

$$P(\emptyset) = P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n) = \sum_{n=1}^{\infty} P(\emptyset)$$

由概率的非负性,  $P(\emptyset) = 0$  □

**Proposition 1.4** (有限可加性). 若  $A_1, \dots, A_n$  是两两互不相容的事件, 则有

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + \dots + P(A_n)$$

证明. 令  $A_{n+1} = A_{n+2} = \dots = \emptyset$ , 即有  $A_i A_j = \emptyset$

$$\begin{aligned} P(A_1 \cup A_2 \cup \dots \cup A_n) \\ &= P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k) \\ &= \sum_{k=1}^{\infty} P(A_k) + 0 = P(A_1) + \dots + P(A_n) \end{aligned}$$

□

**Proposition 1.5.** 设  $A, B$  是两个事件, 若  $A \subset B$ , 则有

$$P(B - A) = P(B) - P(A)$$

$$P(B) \geq P(A)$$

证明.  $B = A \cup (B - A)$

□

**Proposition 1.6.** 对于任一事件  $A$

$$P(A) \leq 1$$

证明.  $P(A) \leq P(S) = 1$

□

**Proposition 1.7** (逆事件的概率). 对于任一事件  $A$ , 有

$$P(\bar{A}) = 1 - P(A)$$

证明.  $P(S) = P(A \cup \bar{A})$

□

**Proposition 1.8** (加法公式). 对于任一两事件  $A, B$  有

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

证明.  $A \cup B = A \cup (B - AB)$

$$P(A \cup B) = P(A) + P(B - AB) = P(A) + P(B) - P(AB)$$

□

可推广到

$$\begin{aligned} P(A_1 \cup A_2 \cup \dots \cup A_n) &= \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) \\ &+ \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) + \dots + (-1)^{n-1} P(A_1 \dots A_n) \end{aligned}$$

## 1.4 等可能概型 (古典概型)

### 等可能概型 (古典概型)

1. 试验的样本空间只包含有限个元素
2. 试验中每个基本事件发生的可能性相同

设试验的样本空间为  $S = \{e_1, \dots, e_n\}$ , 由于在试验中每个基本事件发生的可能性相同, 即

$$P(\{e_1\}) = \dots = P(\{e_n\})$$

又由于基本事件两两互不相容, 于是

$$\begin{aligned} 1 &= P(S) = P(\{e_1\} \cup \dots \cup \{e_n\}) \\ &= P(\{e_1\}) + \dots + P(\{e_n\}) \\ &= nP(\{e_i\}) \end{aligned}$$

于是

$$P(\{e_i\}) = \frac{1}{n}$$

若事件  $A$  包含  $k$  个基本事件, 即  $A = \{e_{i_1}\} \cup \dots \cup \{e_{i_k}\}$ , 则有

$$P(A) = \sum_{j=1}^k P(\{e_{i_j}\}) = \frac{k}{n}$$

**Example 1.1.** 设有  $N$  件产品, 其中有  $D$  件次品, 今从中任取  $n$  件, 文其中恰有  $k(k \leq D)$  件次品的概率

$$p = \frac{\binom{D}{k} \binom{N-D}{n-k}}{\binom{N}{n}}$$

**Example 1.2.** 袋中有  $a$  只白球,  $b$  只红球,  $k$  个人依次在袋中取一只球, 求第  $i$  人取到白球 (记为事件  $B$ ) 的概率 ( $k \leq a+b$ )

共有  $A_{a+b}^k$  个基本事件, 事件  $B$  发生时, 第  $i$  人取的应是白球, 有  $a$  中取法, 剩余  $k-1$  只球有  $A_{a+b-1}^{k-1}$  种取法, 则

$$P(B) = \frac{a \cdot A_{a+b-1}^{k-1}}{A_{a+b}^k} = \frac{a}{a+b}$$

## 1.5 条件概率

**Definition 1.9.** 设  $A, B$  是两个事件, 且  $P(A) > 0$ , 称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件  $A$  发生的条件下事件  $B$  发生的 **条件概率**

条件概率  $P(\cdot|A)$  符合

1. **非负性**: 对于每一事件  $B$ , 有  $P(B|A) \geq 0$
2. **规范性**: 对于必然事件  $S$ , 有  $P(S|A) = 1$
3. **可列可加性**: 设  $B_1, B_2, \dots$  是两两互不相容的事件, 则有

$$P\left(\bigcup_{i=1}^{\infty} B_i | A\right) = \sum_{i=1}^{\infty} P(B_i | A)$$

**Theorem 1.10** (乘法定理). 设  $P(A) > 0$ , 则有

$$P(AB) = P(B|A)P(A)$$

一般地, 设  $A_1, \dots, A_n$  为  $n$  个事件,  $n \geq 2$ , 且  $P(A_1 \dots A_{n-1}) > 0$ , 则有

$$P(A_1 \dots A_n) = P(A_n | A_1 \dots A_{n-1}) P(A_{n-1} | A_1 \dots A_{n-2}) \dots P(A_2 | A_1) P(A_1)$$

**Example 1.3.** 设袋中装有  $r$  只红球,  $t$  只白球, 每次自袋中任取一只球, 观察其颜色再放回, 并再放入  $a$  只与所取出的那只球同色的球, 若在袋中连续取球四次, 试求第一、二次取到红球且第三、四次取到白球的概率

以  $A_i$  表示事件 “第  $i$  次取到红球”, 则

$$\begin{aligned} P(A_1 A_2 \overline{A_3} \overline{A_4}) &= P(\overline{A_4} | A_1 A_2 \overline{A_3}) P(\overline{A_3} | A_1 A_2) P(A_2 | A_1) P(A_1) \\ &= \frac{t+a}{r+t+3a} \cdot \frac{t}{r+t+2a} \cdot \frac{r+a}{r+t+a} \cdot \frac{r}{r+t} \end{aligned}$$

**Definition 1.11.** 设  $S$  为试验  $E$  的样本空间,  $B_1, \dots, B_n$  为  $E$  的一组事件, 若

1.  $B_i B_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$
2.  $B_1 \cup B_2 \cup \dots \cup B_n = S$



则称  $B_1, \dots, B_n$  为样本空间  $S$  的一个 **划分**

**Theorem 1.12.** 设试验  $E$  的样本空间为  $S$ ,  $A$  为  $E$  的事件,  $B_1, \dots, B_n$  为  $S$  的一个划分, 且  $P(B_i) > 0$ , 则

$$P(A) = P(A|B_1)P(B_1) + \dots + P(A|B_n)P(B_n)$$

称为 **全概率公式**

证明.

$$A = AS = A(B_1 \cup \dots \cup B_n) = AB_1 \cup \dots \cup AB_n$$

□

**Theorem 1.13.** 设试验  $E$  的样本空间  $S$ ,  $A$  为  $E$  的事件,  $B_1, \dots, B_n$  为  $S$  的一个划分, 且  $P(A) > 0, P(B_i) > 0$ , 则

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

称为 **贝叶斯公式**

特别的, 取  $n = 2$ , 则

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$$

$$P(B|A) = \frac{AB}{A} = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})}$$

**Example 1.4.** 患肺癌的概率约为 0.1%, 在人群中 20% 是吸烟者, 他们患肺癌的概率约为 0.4%, 求不吸者患肺癌的概率

以  $C$  记事件“患肺癌”, 以  $A$  记事件“吸烟”, 则  $P(C) = 0.001, P(A) = 0.2, P(C|A) = 0.004$ , 由全概率公式

$$P(C) = P(C|A)P(A) + P(C|\bar{A})P(\bar{A})$$

因此

$$P(C|\bar{A}) = 0.00025$$

## 1.6 独立性

**Definition 1.14.** 设  $A, B$  是两事件, 如果满足

$$P(AB) = P(A)P(B)$$

则称事件  $A, B$  **相互独立**, 简称  $A, B$  **独立**

**Theorem 1.15.** 设  $A, B$  是两事件, 且  $P(A) > 0$ , 若  $A, B$  相互独立, 则  $P(B|A) = P(B)$

**Theorem 1.16.** 若事件  $A, B$  相互独立, 则  $A$  与  $\bar{B}$ ,  $\bar{A}$  与  $B$ ,  $\bar{A}$  与  $\bar{B}$  也相互独立

**Definition 1.17.** 设  $A, B, C$  是三个事件, 满足

$$\begin{cases} P(AB) = P(A)P(B) \\ P(BC) = P(B)P(C) \\ P(AC) = P(A)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases}$$

则称事件  $A, B, C$  **相互独立**

一般地, 设  $A_1, \dots, A_n$ , 如果对于  $n$  中任意  $2, 3, \dots, n$  个事件的积事件的概率, 都等于各事件概率之积, 则称事件  $A_1, \dots, A_n$  **相互独立**

**Example 1.5.** 要验收一批 (100) 件乐器, 验收方案如下: 自该批乐器中随机地取 3 件测试 (相互独立), 如果 3 件中至少有一件在测试中被认为音色不纯, 则这批乐器被拒绝接收。设一件音色不纯的乐器经测试查出其音色不纯的概率为 0.05, 而一件音色纯的乐器被误认为不纯的概率为 0.01, 已知 100 中有 4 件音色不纯, 试问这批乐器被接收的概率是多少

设以  $H_i$  表示 3 件中恰有  $i$  件不纯,  $A$  表示这批批乐器被接收, 则

$$P(A|H_0) = 0.99^3, P(A|H_1) = 0.99^2 \times 0.05$$

$$P(A|H_2) = 0.99 \times 0.05^2, P(A|H_3) = 0.05^3$$

而

$$P(H_0) = \frac{\binom{96}{3}}{\binom{100}{3}}, P(H_1) = \frac{\binom{4}{1}\binom{96}{2}}{\binom{100}{3}}$$

$$P(H_2) = \frac{\binom{4}{2}\binom{96}{1}}{\binom{100}{3}}, P(H_3) = \frac{\binom{4}{3}}{\binom{100}{3}}$$

故

$$P(A) = \sum P(A|H_i)P(H_i)$$

## 2 随机变量及其分布

### 2.1 随机变量

**Definition 2.1.** 设随机试验的样本空间为  $S = \{e\}$ ,  $X = X(e)$  是定义在样本空间  $S$  上的实值单值函数, 称  $X = X(e)$  为随机变量

### 2.2 离散型随机变量及其分布律

设离散型随机变量  $X$  所有可能取的值为  $x_k (k = 1, 2, \dots)$ ,  $X$  取各个可能值的概率, 即事件  $\{X = x_k\}$  的概率, 为

$$P\{X = x_k\} = p_k, k = 1, 2, \dots \quad (2.2.1)$$

由概率的定义,  $p_k$  满足如下两个条件

1.  $p_k \geq 0, k = 1, 2, \dots$
2.  $\sum_{k=1}^{\infty} p_k = 1$

我们称 (2.2.1) 为离散型随机变量  $X$  的 **分布律**, 分布律也可以用表格表示

$X$	$x_1$	$x_2$	$\dots$	$x_n$	$\dots$
$p_k$	$p_1$	$p_2$	$\dots$	$p_n$	$\dots$

### 2.2.1 (0-1) 分布

设随机变量  $X$  只可能取 0 与 1 两个值, 它的分布律是

$$P\{X = k\} = p^k(1-p)^{1-k}, k = 0, 1 \quad (0 < p < 1)$$

则称  $X$  服从以  $p$  为参数的 (0-1) 分布或两点分布

### 2.2.2 伯努利试验、二项分布

设试验  $E$  只有两个可能结果:  $A$  及  $\bar{A}$ , 则称  $E$  为 **伯努利试验**. 设  $P(A) = p$  ( $0 < p < 1$ ), 此时  $P(\bar{A}) = 1 - p$ . 将  $E$  独立重复地进行  $n$  次, 则称这一串重复的独立试验为  **$n$  重伯努利试验**

以  $X$  表示  $n$  重伯努利事件  $A$  发生的次数,  $X$  是一个随机变量. 记  $q = 1 - p$ , 即有

$$P\{X = k\} = \binom{n}{k} p^k q^{1-k}$$

注意到  $\binom{n}{k} p^k q^{1-k}$  刚好是  $(p + q)^n$  的展开式中出现  $p^k$  的那一项, 我们称随机变量  $X$  服从参数  $n, p$  的 **二项分布**, 并记为  $X \sim b(n, p)$

### 2.2.3 泊松分布

设随机变量  $X$  所有可能的值为  $0, 1, 2, \dots$ , 而各个值的概率为

$$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}$$

其中  $\lambda > 0$  是常数, 则称  $X$  服从参数  $\lambda$  的 **泊松分布**, 记为  $X \sim \pi(\lambda)$

易知  $P\{X = k\} \geq 0, k = 0, 1, 2, \dots$ , 且有

$$\sum_{k=0}^{\infty} P\{X = k\} = \sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$$

**Theorem 2.2** (泊松定理). 设  $\lambda > 0$  是一个常数,  $n$  是任意正整数, 设  $np_n = \lambda$ , 则对于任意固定的非负整数  $k$ , 有

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

证明. 设  $p_n = \frac{\lambda}{n}$ , 有

$$\begin{aligned} \binom{n}{k} p_n^k (1 - p_n)^{n-k} &= \frac{n(n-1) \dots (n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &= \frac{\lambda^k}{k!} \left[\left(1 - \frac{1}{n}\right) \dots \left(1 - \frac{k-1}{n}\right)\right] \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \end{aligned}$$

当  $n \rightarrow \infty$  时  $\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}$ , 故有

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

□

也就是说以  $n, p$  为参数的二项分布的概率值可以由参数为  $\lambda = np$  的泊松分布的概率值近似

## 2.3 随机变量的分布函数

**Definition 2.3.** 设  $X$  是一个随机变量,  $x$  是任意实数, 函数

$$F(x) = P\{X \leq x\}, -\infty < x < \infty$$

称为  $X$  的 **分布函数**

对于任意实数  $x_1, x_2 (x_1 < x_2)$ , 有

$$\begin{aligned} P\{x_1 < X \leq x_2\} &= P\{X \leq x_2\} - P\{X \leq x_1\} \\ &= F(x_2) - F(x_1) \end{aligned}$$

分布函数  $F(x)$  具有以下的基本性质

1.  $F(x)$  是一个不减函数
2.  $0 \leq F(x) \leq 1$ , 且

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$$

$$F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$$

3.  $F(x+0) = F(x)$

## 2.4 连续型随机变量及其概率密度

如果对于随机变量  $X$  的分布函数  $F(x)$ , 存在非负函数  $f(x)$  使对于任意实数  $x$  有

$$F(x) = \int_{-\infty}^x f(t)dt$$

则称  $X$  为 **连续型随机变量**, 其中函数  $f(x)$  称为  $X$  的 **概率密度函数**, 简称 **概率密度**

概率密度  $f(x)$  具有以下性质

1.  $f(x) \geq 0$
2.  $\int_{-\infty}^{\infty} f(x)dx = 1$
3. 对于任意实数  $x_1, x_2 (x_1 \leq x_2)$ ,

$$P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx$$

4. 若  $f(x)$  在点  $x$  处连续, 则有  $F'(x) = f(x)$

### 2.4.1 均匀分布

若连续型随机变量  $X$  有概率密度

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{其他} \end{cases}$$

则称  $X$  在区间  $(a, b)$  上服从 **均匀分布**, 记为  $X \sim U(a, b)$ 。分布函数

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x < b \\ 1 & x \geq b \end{cases}$$

### 2.4.2 指数分布

若连续型随机变量  $X$  的概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & x > 0 \\ 0 & \text{其他} \end{cases}$$

其中  $\theta > 0$  为常数, 则称  $X$  服从参数  $\theta$  的 **指数分布**

$$F(x) = \begin{cases} 1 - e^{-x/\theta} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

对于任意  $s, t > 0$ , 有

$$P\{X > s + t | X > s\} = P\{X > t\}$$

事实上

$$\begin{aligned} P\{X > s + t | X > s\} &= \frac{P\{(X > s + t) \cap (X > s)\}}{P\{X > s\}} \\ &= \frac{P\{X > s + t\}}{P\{X > s\}} = \frac{1 - F(s + t)}{1 - F(s)} \\ &= e^{-t/\theta} = P\{X > t\} \end{aligned}$$

这个性质称为无记忆性

### 2.4.3 正态分布

若连续型随机变量  $X$  的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

其中  $\mu, \sigma (\sigma > 0)$  为常数, 则称  $X$  服从参数为  $\mu, \sigma$  的 **正态分布** 或 **高斯分布**, 记为  $X \sim N(\mu, \sigma^2)$

令  $(x-\mu)/\sigma = t$ , 记  $I = \int_{-\infty}^{\infty} e^{-t^2/2} dt$ , 则有  $I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(t^2+u^2)/2} dt du$ , 利用极坐标得

$$I^2 = \int_0^{2\pi} \int_0^{\infty} r e^{-r^2/2} dr d\theta = 2\pi$$

$f(x)$  有以下性质

1. 曲线关于  $x = \mu$  对称
2. 当  $x = \mu$  时取得最大值

$$f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$$

特别的, 当  $\mu = 0, \sigma = 1$  时称随机变量  $X$  服从 **标准正态分布**, 其概率密度和分布函数分别用  $\varphi(x), \Phi(x)$  表示, 即

$$\begin{aligned}\varphi(x) &= \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \\ \Phi(x) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt\end{aligned}$$

易知

$$\Phi(-x) = 1 - \Phi(x)$$

**Lemma 2.4.** 若  $X \sim N(\mu, \sigma^2)$ , 则  $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$

于是, 若  $X \sim N(\mu, \sigma^2)$ , 则

$$F(x) = P\{X \leq x\} = P\left\{\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right\} = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

## 2.5 随机变量的函数的分布

**Example 2.1.** 设随机变量  $X$  具有概率密度  $f_X(x), -\infty < x < \infty$ , 求  $Y = X^2$  的概率密度

分别记  $X, Y$  的分布函数为  $F_X(x), F_Y(y)$ , 当  $y > 0$  时

$$\begin{aligned}F_Y(y) &= P\{Y \leq y\} = \{X^2 \leq y\} \\ &= P\{-\sqrt{y} \leq X \leq \sqrt{y}\} \\ &= F_X(\sqrt{y}) - F_X(-\sqrt{y})\end{aligned}$$

因此

$$f_Y(y) = \begin{cases} \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] & y > 0 \\ 0 & y \leq 0 \end{cases}$$

**Theorem 2.5.** 设随机变量  $X$  具有概率密度  $f_X(x), -\infty < x < \infty$ , 又设函数  $g(x)$  处处可导且恒有  $g'(x) > 0$  (或恒有  $g'(x) < 0$ ), 则  $Y = g(x)$  是连续型随机变量, 其概率密度为

$$f_Y(y) = \begin{cases} f_X[h(y)]|h'(y)| & \alpha < y < \beta \\ 0 & \end{cases}$$



### 3 多维随机变量及其分布

其中  $\alpha = \min\{g(-\infty), g(\infty)\}, \beta = \max\{g(-\infty), g(\infty)\}$ ,  $h(y)$  是  $g(x)$  的反函数

**Proposition 2.6.** 设随机变量  $X \sim N(\mu, \sigma^2)$ , 试证明  $X$  的线性函数  $Y = aX + b (a \neq 0)$  也服从正态分布

证明.  $X$  的概率密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

由  $Y = aX + b$

$$x = \frac{y-b}{a}, h'(y) = \frac{1}{a}$$

因此

$$\begin{aligned} f_Y(y) &= \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right), -\infty < y < \infty \\ &= \frac{1}{|a|\sigma\sqrt{2\pi}} e^{-\frac{(\frac{y-b}{a}-\mu)^2}{2(a\sigma)^2}} \end{aligned}$$

即有  $Y = aX + B \sim N(a\mu + b, (a\sigma)^2)$  □

## 3 多维随机变量及其分布

### 3.1 二维随机变量

设  $E$  是一个随机试验, 它的样本空间是  $S = \{e\}$ , 设  $X = X(e), Y = Y(e)$  是定义在  $S$  上的随机变量, 它们构成的一个向量  $(X, Y)$  叫做 **二维随机向量** 或 **二维随机变量**

**Definition 3.1.** 设  $(X, Y)$  是二维随机变量, 对于任意实数  $x, y$ , 二元函数

$$F(x, y) = P\{(X \leq x) \cap (Y \leq y)\} \text{ (written as } P\{X \leq x, Y \leq y\})$$

称为二维随机变量的 **分布函数**, 或称为随机变量  $X, Y$  的 **联合分布函数**

分布函数  $F(x, y)$  具有以下性质

1.  $F(x, y)$  是变量  $x, y$  的不减函数
2.  $0 \leq F(x, y) \leq 1$ , 且

$$\forall y, F(-\infty, y) = 0$$

$$\forall x, F(x, -\infty) = 0$$

$$F(-\infty, -\infty) = 0, F(\infty, \infty) = 1$$

3.  $F(x+0, y) = F(x, y), F(x, y+0) = F(x, y)$ , 即  $F(x, y)$  关于  $x$  又连续, 关于  $y$  也右连续
4. 对于任意  $(x_1, y_1), (x_2, y_2), x_1 < x_2, y_1 < y_2$ , 下列不等式成立

$$F(x_2, y_2) - F(x_2, y_1) + F(x_1, y_1) - F(x_1, y_2) \geq 0$$

如果二维随机变量  $(X, Y)$  全部可能取到的值是有限对或可列无限多对, 则称  $(X, Y)$  是 **离散型的随机变量**

设二维离散型随机变量  $(X, Y)$  所有可能取的值为  $(x_i, y_j), i, j = 1, 2, \dots$ , 记  $P\{X = x_i, Y = y_j\} = p_{ij}$ , 称为二维离散型随机变量  $(X, Y)$  的 **分布律**, 或随机变量  $X, Y$  的 **联合分布律**

$Y, X$	$x_1$	$\dots$	$x_i$	$\dots$
$y_1$	$p_{11}$	$\dots$	$p_{i1}$	$\dots$
$\vdots$				
$y_j$	$p_{1j}$		$p_{ij}$	

对于二维随机变量  $(X, Y)$  的分布函数  $F(x, y)$ , 如果存在非负的函数  $f(x, y)$  使对于任意  $x, y$  有

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv$$

则称  $(X, Y)$  是 **连续型的二维随机变量**, 函数  $f(x, y)$  称为二维随机变量的 **概率密度**, 或称为随机变量  $X, Y$  的 **联合概率密度**

概率密度  $f(x, y)$  具有以下性质

1.  $f(x, y) \geq 0$
2.  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$

3. 设  $G$  是  $xOy$  平面的区域, 点  $(X, Y)$  落在  $G$  内的概率为

$$P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy$$

4. 若  $f(x, y)$  在点  $(x, y)$  连续, 则有

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

### 3.2 边缘分布

$F_X(x), F_Y(y)$  称为二维随机变量  $(X, Y)$  关于  $X, Y$  的 **边缘分布函数**

$$F_x(x) = P\{X \leq x\} = P\{X \leq x, Y < \infty\} = F(x, \infty)$$

记

$$p_{i \cdot} = \sum_{j=1}^{\infty} p_{ij} = P\{X = x_i\}$$

$$p_{\cdot j} = \sum_{i=1}^{\infty} p_{ij} = P\{Y = y_j\}$$

分别称为  $p_{i \cdot}$  和  $p_{\cdot j}$  为  $(X, Y)$  关于  $X, Y$  的 **边缘分布律**

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

分别为  $X, Y$  的 **边缘概率密度**

**Example 3.1.** 设二维随机变量  $(X, Y)$  的概率密度

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[ \frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}$$

其中  $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$  都是常数, 且  $\sigma_1, \sigma_2 > 0, -1 < \rho < 1$ , 我们称  $(X, Y)$  服从参数为  $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$  的**二维正态分布**, 记为  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 试求二维正态分布随机变量的边缘概率密度

令  $t = \frac{1}{\sqrt{1-\rho^2}}(\frac{y-\mu_2}{\sigma_2} - \rho\frac{x-\mu_1}{\sigma_1})$ , 则有

$$f_X(x) = \frac{1}{2\pi\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt$$

即

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$$

### 3.3 条件分布

**Definition 3.2.** 设  $(X, Y)$  是二维离散型随机变量, 对于固定的  $j$ , 若  $P\{Y = y_j\} > 0$ , 则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{.j}}$$

为在  $Y = y_j$  条件下随机变量  $X$  的**条件分布律**

**Definition 3.3.** 设二维随机变量  $(X, Y)$  的概率密度为  $f(x, y)$ ,  $(X, Y)$  关于  $Y$  的边缘概率密度为  $f_Y(y)$ , 若对于固定的  $y$ ,  $f_Y(y) > 0$ , 则称  $\frac{f(x, y)}{f_Y(y)}$  为在  $Y = y$  的条件下  $X$  的**条件概率密度**, 记为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

称  $F_{X|Y}(x|y) = \int_{-\infty}^x f_{X|Y}(x|y) dx = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$  为在  $Y = y$  下  $X$  的条件分布函数

### 3.4 相互独立的随机变量

**Definition 3.4.** 设  $F(x, y)$  及  $F_X(x), F_Y(y)$  分别是二维随机变量  $(X, Y)$  的分布函数及边缘分布函数, 若对于所有  $x, y$  有

$$P\{X \leq x, Y \leq y\} = P\{X \leq x\}P\{Y \leq y\}$$

$$F(x, y) = F_X(x)F_Y(y)$$

$$f(x, y) = f_X(x)f_Y(y)$$

则称  $X, Y$  是 **相互独立的**

下面考查二维正态随机变量  $(X, Y)$ , 它的概率密度为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[ \frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}$$

如果  $\rho = 0$  则对于所有  $x, y, f(x, y) = f_X(x)f_Y(y)$ 。如果  $X, Y$  相互独立, 令  $x = \mu_1, y = \mu_2$ , 则  $\rho = 0$

对于二维正态随机变量  $(X, Y)$ ,  $X, Y$  相互独立的充要条件是参数  $\rho = 0$

**Theorem 3.5.** 设  $(X_1, \dots, X_m)$  和  $(Y_1, \dots, Y_n)$  相互独立, 则  $X_i$  和  $Y_j$  相互独立。又若  $h, g$  是连续函数, 则  $h(X_1, \dots, X_m)$  和  $g(Y_1, \dots, Y_n)$  相互独立

### 3.5 两个随机变量的函数的分布

#### 3.5.1 $Z = X + Y$ 分布

设  $(X, Y)$  是二维连续型随机变量, 它具有概率密度  $f(x, y)$ , 则  $Z = X + Y$  仍为连续型随机变量, 其概率密度为

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(z-y, y)dy$$

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(x, z-x)dx$$

又设  $X, Y$  相互独立, 则

$$\begin{aligned} f_{X+Y}(z) &= \int_{-\infty}^{\infty} f_X(z-y)f_Y(y)dy \\ f_{X+Y}(z) &= \int_{-\infty}^{\infty} f_X(x)f_Y(z-x)dx \end{aligned}$$

称为  $f_X, f_Y$  的 **卷积公式**, 记为  $f_X * f_Y$ , 即

$$f_X * f_Y = \int_{-\infty}^{\infty} f_X(z-y)f_Y(y)dy = \int_{-\infty}^{\infty} f_X(x)f_Y(z-x)dx$$

证明.

$$F_Z(z) = P\{Z \leq z\} = \iint_{x+y \leq z} f(x, y) dx dy$$

则

$$\begin{aligned} F_z(z) &= \int_{-\infty}^{\infty} \left[ \int_{-\infty}^{z-y} f(x, y) dx \right] dy \\ F_z(z) &= \int_{-\infty}^{\infty} \left[ \int_{-\infty}^z f(u-y, y) du \right] dy \\ F_z(z) &= \int_{-\infty}^z \left[ \int_{-\infty}^{\infty} f(u-y, y) dy \right] du \end{aligned}$$

□

有限个相互独立的正态随机变量的线性组合仍服从正态分布

**Example 3.2.** 设随机变量  $X, Y$  相互独立, 且分别服从参数为  $\alpha, \theta; \beta, \theta$  的  $\Gamma$  分布 (分别记成  $X \sim \Gamma(\alpha, \theta), Y \sim \Gamma(\beta, \theta)$ ),  $X, Y$  的概率密度分别为

$$\begin{aligned} f_X(x) &= \begin{cases} \frac{1}{\theta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta} & x > 0 \\ 0 & x \leq 0 \end{cases}, \alpha > 0, \theta > 0 \\ f_Y(y) &= \begin{cases} \frac{1}{\theta^\beta \Gamma(\beta)} y^{\beta-1} e^{-y/\theta} & y > 0 \\ 0 & y \leq 0 \end{cases}, \beta > 0, \theta > 0 \end{aligned}$$

试证明  $X + Y \sim \Gamma(\alpha + \beta, \theta)$

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z-x)dx$$

仅当  $0 < x < z$  时被积函数不等于零, 当  $z < 0$  时  $f_Z(z) = 0$ , 当  $z > 0$  有

$$\begin{aligned} f_Z(z) &= \int_0^x \frac{1}{\theta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta} \frac{1}{\theta^\beta \Gamma(\beta)} (z-x)^{\beta-1} e^{-(z-x)/\theta} ds \\ &= \frac{e^{-z/\theta}}{\theta^{\alpha+\beta} \Gamma(\alpha) \Gamma(\beta)} \int_0^z x^{\alpha-1} (z-x)^{\beta-1} dx (\text{let } x = zt) \\ &= \frac{z^{\alpha+\beta-1} e^{-z/\theta}}{\theta^{\alpha+\beta} \Gamma(\alpha) \Gamma(\beta)} \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt \\ &= A z^{\alpha+\beta-1} e^{-z/\theta} \end{aligned}$$

其中  $A = \frac{1}{\theta^{\alpha+\beta} \Gamma(\alpha) \Gamma(\beta)} \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt$  由概率密度的性质得

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} f_Z(z) dz = \int_0^{\infty} A z^{\alpha+\beta-1} e^{-z/\theta} dz \\ &= A \theta^{\alpha+\beta} \int_0^{\infty} (z/\theta)^{\alpha+\beta-1} e^{-z/\theta} d(z/\theta) \\ &= A \theta^{\alpha+\beta} \Gamma(\alpha + \beta) \end{aligned}$$

### 3.5.2 $Z = \frac{Y}{X}, Z = XY$ 的分布

$$\begin{aligned} f_{Y/X}(z) &= \int_{-\infty}^{\infty} |x| f(x, xz) dx \\ f_{XY}(z) &= \int_{-\infty}^{\infty} \frac{1}{|x|} f(x, \frac{z}{x}) dx \end{aligned}$$

### 3.5.3 $M = \max\{X, Y\}, N = \min\{X, Y\}$ 的分布

对于  $n$  个相互独立的随机变量

$$\begin{aligned} F_{\max}(z) &= [F(z)]^n \\ F_{\min}(z) &= 1 - [1 - F(z)]^n \end{aligned}$$

## 4 随机变量的数字特征

### 4.1 数学期望

**Definition 4.1.** 设离散型随机变量  $X$  的分布律

$$P\{X = x_k\} = p_k, k = 1, 2, \dots$$

若级数

$$\sum_{k=1}^{\infty} x_k p_k$$

绝对收敛, 则称级数  $\sum_{k=1}^{\infty} x_k p_k$  的和为随机变量  $X$  的 **数学期望**, 记为  $E(X)$

若连续型随机变量  $X$  的概率密度为  $f(x)$ , 若积分

$$\int_{-\infty}^{\infty} x f(x) dx$$

绝对收敛, 则称积分  $\int_{-\infty}^{\infty} x f(x) dx$  的值为随机变量  $X$  的 **数学期望**, 记为  $E(X)$

**Example 4.1.** 设  $X \sim \pi(\lambda)$ , 求  $E(X)$

$$E(X) = \sum_{k=0}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

**Theorem 4.2.** 设  $Y$  是随机变量  $X$  的函数:  $Y = g(X)$  ( $g$  是连续函数)

1. 如果  $X$  是离散型随机变量, 它的分布律为  $P\{X = x_k\} = p_k$ , 若  $\sum_{k=1}^{\infty} g(x_k) p_k$  绝对收敛, 则

$$E(Y) = E[g(X)] = \sum_{k=1}^{\infty} g(x_k) p_k$$

2. 如果  $X$  是连续型随机变量, 它的概率密度为  $f(x)$ , 若  $\int_{-\infty}^{\infty} g(x) f(x) dx$  绝对收敛, 则

$$E(Y) = E[g(X)] = \int_{-\infty}^{\infty} g(x) f(x) dx$$

数学期望的几个重要性质



1. 设  $C$  是常数, 则  $E(C) = C$
2. 设  $X$  是一个随机变量,  $C$  是常数, 则有

$$E(CX) = CE(X)$$

3. 设  $X, Y$  是两个随机变量, 则有

$$E(X + Y) = E(X) + E(Y)$$

4. 设  $X, Y$  是相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y)$$

## 4.2 方差

**Definition 4.3.** 设  $X$  是一个随机变量, 若  $E\{[X - E(X)]^2\}$  存在, 则称  $E\{[X - E(X)]^2\}$  为  $X$  的 **方差**, 记为  $D(X)$  或  $Var(X)$

$\sqrt{D(X)}$ , 记为  $\sigma(X)$ , 称为 **标准差**或 **均方差**

**Theorem 4.4.**  $D(X) = E(X^2) - [E(X)]^2$

**Example 4.2.** 设随机变量  $X$  具有数学期望  $E(X) = \mu$ , 方差  $D(X) = \sigma^2 \neq 0$ , 记

$$X^* = \frac{X - \mu}{\sigma}$$

则

$$E(X^*) = 0$$

$$D(X^*) = 1$$

即  $X^* = \frac{X - \mu}{\sigma}$  的数学期望为 0, 方差为 1,  $X^*$  称为  $X$  的 **标准化变量**

**Example 4.3.** 设随机变量  $X \sim \pi(\lambda)$ , 求  $D(X)$

随机变量  $X$  的分布律为

$$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}$$

因为  $E(X) = \lambda$ , 而

$$\begin{aligned} E(X^2) &= E[X(X-1) + X] = E[X(X-1)] + E(X) = \\ &= \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k e^{-\lambda}}{k!} + \lambda = \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + \lambda \\ &= \lambda^2 + \lambda \end{aligned}$$

所以方差

$$D(X) = \lambda$$

**Example 4.4.** 设随机变量  $X \sim U(a, b)$ , 求  $D(X)$

$E(X) = \frac{a+b}{2}$ , 方差为

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 \\ &= \int_a^b x^2 \frac{1}{b-a} dx - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12} \end{aligned}$$

**Example 4.5.** 设随机变量  $X$  服从指数分布, 其概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

其中  $\theta > 0$ , 求  $E(X), D(X)$

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx = \theta$$

$$E(X^2) = 2\theta^2$$

$$D(X) = \theta^2$$

方差的几个性质

1. 设  $C$  是常数, 则  $D(C) = 0$
2. 设  $X$  是随机变量,  $C$  是常数, 则有

$$D(CX) = C^2 D(X), D(X+C) = D(X)$$

3. 设  $X, Y$  是两个随机变量, 则有

$$D(X + Y) = D(X) + D(Y) + 2E\{(X - E(X))(Y - E(Y))\}$$

特别地, 若  $X, Y$  相互独立, 则

$$D(X + Y) = D(X) + D(Y)$$

4.  $D(X) = 0$  的充要条件是  $X$  以概率 1 取常数  $E(X)$

**Example 4.6.** 设随机变量  $X \sim b(n, p)$ , 求  $E(X), D(X)$

引入随机变量

$$X_k = \begin{cases} 1 & A \text{ happens at } k\text{th} \\ 0 & \end{cases}$$

易知  $X = X_1 + \cdots + X_n$ 。因为  $E(X_k) = p, D(X_k) = p(1 - p)$ , 故

$$E(X) = E\left(\sum_{k=1}^n X_k\right) = np$$

$$D(X) = D\left(\sum_{k=1}^n X_k\right) = np(1 - p)$$

**Example 4.7.** 设随机变量  $X \sim N(\mu, \sigma^2)$ , 求  $E(X), D(X)$

先求标准正态变量

$$Z = \frac{X - \mu}{\sigma}$$

的数学期望和方差,  $Z$  的概率密度为

$$\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$$

于是

$$E(Z) = 0$$

$$D(Z) = E(Z^2) = 1$$

因  $X = \mu + \sigma Z$ , 即得

$$E(X) = E(\mu + \sigma Z) = \mu$$

$$D(X) = \sigma^2$$

推广得

$$C_1X_1 + \cdots + C_nX_n \sim N\left(\sum_{i=1}^n C_i\mu_i, \sum_{i=1}^n C_i^2\sigma_i^2\right)$$

**Definition 4.5** (切比雪夫不等式). 设随机变量  $X$  具有数学期望  $E(X) = \mu$ , 方差  $D(X) = \sigma^2$ , 则对于任意正数  $\epsilon$ , 不等式

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

### 4.3 协方差及相关系数

**Definition 4.6.**  $E\{[E - E(X)][Y - E(Y)]\}$  称为随机变量  $X$  与  $Y$  的 **协方差**, 记为  $Cov(X, Y)$ ,

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

称为随机变量  $X$  与  $Y$  的 **相关系数**

有

$$D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$$

$$Cov(X, Y) = E(XY) - E(X)E(Y)$$

协方差有以下性质

1.  $Cov(aX, bY) = abCov(X, Y)$
2.  $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

考虑以  $X$  的线性函数  $a + bX$  来近似表示  $Y$ , 我们以均方误差

$$\begin{aligned} e &= E[(Y - (a + bX))^2] \\ &= E(Y^2) + b^2E(X^2) + a^2 - 2bE(XY) + 2abE(X) - 2aE(Y) \end{aligned}$$

来衡量以  $a + bX$  近似表达  $Y$  的好坏程度。将  $e$  分别关于  $a, b$  求偏到, 得

$$\begin{cases} \frac{\partial e}{\partial a} = 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial e}{\partial b} = 2bE(X^2) - 2E(XY) + 2aE(X) = 0 \end{cases}$$

解得

$$b_0 = \frac{Cov(X, Y)}{D(X)}$$

$$a_0 = E(Y) - b_0 E(X)$$

代入得

$$\min_{a, b} E\{[Y - (a + bX)]^2\} = (1 - \rho_{xy}^2)D(Y)$$

**Theorem 4.7.** 1.  $|\rho_{xy}| \leq 1$

2.  $|\rho_{xy}| = 1$  的充要条件是存在  $a, b$  使得

$$P\{Y = a + bX\} = 1$$

当  $\rho_{xy} = 0$  时, 称  $X$  和  $Y$  不相关

**Example 4.8.** 设  $(X, Y)$  服从二维正态分布, 求  $X, Y$  的相关系数

$$\rho_{xy} = \rho$$

#### 4.4 矩、协方差矩阵

**Definition 4.8.** 设  $X, Y$  是随机变量, 若

$$E(X^k), k = 1, 2, \dots$$

存在, 称它为  $X$  的  $k$  阶原点矩, 简称  $k$  阶矩

若

$$E\{[E - E(X)]^k\}, k = 2, 3, \dots$$

存在, 称它为  $X$  的  $k$  阶中心矩

若

$$E(X^k Y^l), k, l = 1, 2, \dots$$

存在, 称它为  $X, Y$  的  $k + l$  阶混合矩

若

$$E\{[E - E(X)]^k [Y - E(Y)]^l\}, k, l = 1, 2, \dots$$

存在, 称它为  $X, Y$  的  $k + l$  阶混合中心矩

## 5 大数定律及中心极限定理

### 5.1 大数定律

**Theorem 5.1** (弱大数定理 (辛钦大数定理)). 设  $X_1, X_2, \dots$  是相互独立, 服从同一分布的随机变量序列, 且具有数学期望  $E(X_k) = \mu$ , 作前  $n$  个变量的算术平均  $\frac{1}{n} \sum_{k=1}^n X_k$ , 则对于任意  $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \epsilon \right\} = 1$$

对于独立同分布且具有均值  $\mu$  的随机变量  $X_1, \dots, X_n$ , 当  $n$  很大时它们的算术平均  $\frac{1}{n} \sum_{k=1}^n X_k$  很可能接近  $\mu$

设  $Y_1, \dots, Y_n, \dots$  是一个随机变量序列,  $a$  是一个常数, 若对于任意正数  $\epsilon$ , 有

$$\lim_{n \rightarrow \infty} P\{|Y_n - a| < \epsilon\} = 1$$

则称序列  $Y_1, \dots, Y_n, \dots$  依概率收敛于  $a$ , 记为

$$Y_n \xrightarrow{P} a$$

设  $X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b$ , 又设函数  $g(x, y)$  在点  $(a, b)$  连续, 则

$$g(X_n, Y_n) \xrightarrow{P} g(a, b)$$

这样上述定理可叙述为

**Theorem 5.2** (弱大数定理 (辛钦大数定理)). 设随机变量  $X_1, \dots, X_n, \dots$  相互独立, 服从同一分布且具有数学期望  $E(X_k) = \mu$ , 则序列  $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$  依概率收敛于  $\mu$ , 即  $\bar{X} \xrightarrow{P} \mu$

**Theorem 5.3** (伯努利大数定理). 设  $f_A$  是  $n$  次独立重复试验中事件  $A$  发生的次数,  $p$  是事件  $A$  在每次试验中发生的概率, 则对于任意正数  $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| < \epsilon \right\} = 1$$

或

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| \geq \epsilon \right\} = 0$$

## 5.2 中心极限定理

**Theorem 5.4** (独立同分布的中心极限定理). 设随机变量  $X_1, \dots, X_n, \dots$  相互独立, 服从同一分布, 且具有数学期望和方差:  $E(X_k) = \mu, D(X_k) = \sigma^2 > 0$ , 则随机变量之和  $\sum_{k=1}^n X_k$  的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$$

的分布函数  $F_n(x)$  对于任意  $x$  满足

$$\begin{aligned} \lim_{n \rightarrow \infty} F_n(x) &= \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x \right\} \\ &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x) \end{aligned}$$

因此当  $n$  充分大时, 有

$$\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

或

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

**Theorem 5.5** (李雅普诺夫定理). 设随机变量  $X_1, \dots, X_n, \dots$  相互独立, 它们具有数学期望和方差

$$E(X_k) = \mu_k, D(X_k) = \sigma_k^2 > 0$$

记

$$B_n^2 = \sum_{k=1}^n \sigma_k^2$$

若存在正数  $\delta$  使得当  $n \rightarrow \infty$  时

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0$$

则随机变量之和  $\sum_{k=1}^n X_k$  的标准化变量

$$Z_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

的分布函数  $F_n(x)$  对于任意  $x$  满足

$$\begin{aligned} \lim_{n \rightarrow \infty} F_n(x) &= \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \leq x \right\} \\ &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x) \end{aligned}$$

定理表明, 在定理的条件下, 随机变量

$$Z_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

当  $n$  很大时, 近似服从正态分布  $N(0, 1)$

**Theorem 5.6** (棣莫弗-拉普拉斯定理). 设随机变量  $\eta_n$  服从参数为  $n, p$  的二项分布, 则对于任意  $x$  有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

## 6 样本及抽样分布

### 6.1 随机样本

我们将试验的全部可能的观察值称为 **总体**, 每一个可能观察值称为 **个体**, 总体中所包含的个体的个数称为总体的 **容量**, 容量为有限的称为 **有限总体**, 容量为无限的称为 **无限总体**

**Definition 6.1.** 设  $X$  是具有分布函数  $F$  的随机变量, 若  $X_1, \dots, X_n$  是具有同一分布函数  $F$  的、相互独立的随机变量, 则称  $X_1, \dots, X_n$  为从分布函数  $F$  得到的 **容量为  $n$  的简单随机样本**, 简称为 **样本**, 它们的观察值  $x_1, \dots, x_n$  称为 **样本值**, 又称为  $X$  的  $n$  个 **独立的观察值**



## 6.2 抽样分布

**Definition 6.2.** 设  $X_1, \dots, X_n$  是来自总体  $X$  的一个样本  $g(X_1, \dots, X_n)$  是  $X_1, \dots, X_n$  的函数, 若  $g$  中不含未知参数, 则称  $g(X_1, \dots, X_n)$  是一 **统计量**

$g(x_1, \dots, x_n)$  是  $g(X_1, \dots, X_n)$  的观察值

定义

**样本平均值**

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

**样本方差**

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$$

**样本标准差**

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

**样本  $k$  阶 (原点) 矩**

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots$$

**样本  $k$  阶中心矩**

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 2, 3, \dots$$

若总体  $X$  的  $k$  阶矩  $E(X^k) = \mu_k$  存在, 则当  $n \rightarrow \infty$  时,  $A_k \xrightarrow{P} \mu_k$ , 这时因为  $X_1, \dots, X_n$  独立且与  $X$  同分布, 所以  $X_1^k, \dots, X_n^k$  独立且与  $X_k$  同分布, 故有

$$E(X_1^k) = \dots = E(X_n^k) = \mu_k$$

从而由辛钦大数定理

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$$

进而由依概率收敛的序列的性质知道

$$g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k)$$

### 6.2.1 $\chi^2$ 分布

设  $X_1, \dots, X_n$  是来自总体  $N(0, 1)$  的样本, 则称统计量

$$\chi^2 = X_1^2 + \dots + X_n^2$$

服从自由度为  $n$  的  $\chi^2$  分布, 记为  $\chi^2 \sim \chi^2(n)$

$\chi^2(n)$  分布的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{n/2-1} e^{-y/2} & y > 0 \\ 0 & y \leq 0 \end{cases}$$




图 6-6

由 2.1 及 3.2 知  $\chi^2(1)$  服从  $\Gamma(0.5, 2)$  分布。现  $X_i \sim N(0, 1)$  由定义  $X_i^2 \sim \chi^2(1)$ , 即  $X_i^2 \sim \Gamma(0.5, 2)$ , 因此

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right)$$

**$\chi^2$  分布的可加性** 设  $\chi_1^2 \sim \chi^2(n_1)$ ,  $\chi_2^2 \sim \chi^2(n_2)$  且  $\chi_1^2, \chi_2^2$  相互独立, 则有

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$$

$\chi^2$  分布的数学期望和方差若  $\chi^2 \sim \chi^2(n)$ , 则有

$$E(\chi^2) = n, D(\chi^2) = 2n$$

$\chi^2$  分布的分位点对于给定的正数  $\alpha$ ,  $0 < \alpha < 1$  称满足条件

$$P\{\chi^2 > \chi^2_\alpha(n)\} = \int_{\chi^2_\alpha}^{\infty} f(y)dy = \alpha$$

的点  $\chi^2_\alpha(n)$  为  $\chi^2(n)$  分布的上  $\alpha$  分位点

### 6.2.2 $t$ 分布

设  $X \sim N(0, 1), Y \sim \chi^2(n)$ , 且  $X, Y$  相互独立, 则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为  $n$  的  $t$  分布, 记为  $t \sim t(n)$

$t$  分布又称 **学生式 (Student) 分布**,  $t(n)$  分布的概率密度函数为

$$h(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, -\infty < t < \infty$$

$$\lim_{n \rightarrow \infty} h(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$$

### 6.2.3 $F$ 分布

设  $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$ , 且  $U, V$  相互独立, 则称随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度  $(n_1, n_2)$  的  $F$  分布, 记为  $F \sim F(n_1, n_2)$

由定义得

$$\frac{1}{F} \sim F(n_2, n_1)$$

$F$  分布的上  $\alpha$  分位点有如下性质

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$$

### 6.3 正态总体的样本均值与样本方差的分布

设总体  $X$  的均值为  $\mu$ , 方差为  $\sigma^2$ ,  $X_1, \dots, X_n$  是来自  $X$  的一个样本,  $\bar{X}, S^2$  分别是样本均值和样本方差, 则

$$E(\bar{X}) = \mu, \quad D(\bar{X}) = \sigma^2/n$$

而

$$\begin{aligned} E(S^2) &= E \left[ \frac{1}{n-1} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) \right] = \frac{1}{n-1} \left[ \sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right] \\ &= \frac{1}{n-1} \left[ \sum_{i=1}^n (\sigma^2 + \mu^2) - n(\sigma^2/n + \mu^2) \right] = \sigma^2 \end{aligned}$$

即

$$E(S^2) = \sigma^2$$

进而, 设  $X \sim N(\mu, \sigma^2)$ , 则  $\bar{X}$  也服从正态分布, 则

**Theorem 6.3.** 设  $X_1, \dots, X_n$  是来自正态总体  $N(\mu, \sigma^2)$  的样本,  $\bar{X}$  是样本均值, 则有

1.  $\bar{X} \sim N(\mu, \sigma^2/n)$
2.  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
3.  $\bar{X}$  与  $S^2$  相互独立
4.  $\frac{\bar{X}}{S/\sqrt{n}} \sim t(n-1)$

**Theorem 6.4.** 设  $X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}$  分别是来自正态总体  $N(\mu_1, \sigma_1^2)$  和  $N(\mu_2, \sigma_2^2)$  的样本, 且这两个样本相互独立, 设  $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i$  为分别是两样本的均值,  $S_1^2, S_2^2$  分别是两样本的样本方差, 则有

1.  $\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$
2. 当  $\sigma_1^2 = \sigma_2^2 = \sigma^2$  时

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$\text{其中 } S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}, S_w = \sqrt{S_w^2}$$

## 7 参数估计

### 7.1 点估计

#### 7.1.1 矩估计法

设  $X$  为连续型随机变量，其概率密度函数为  $f(x; \theta_1, \dots, \theta_k)$ ，或  $X$  为离散型随机变量，其分布律为  $P\{X = x\} = p(x; \theta_1, \dots, \theta_k)$ ，其中  $\theta_1, \dots, \theta_k$  为待估计参数， $X_1, \dots, X_n$  是来自  $X$  的样本，假设总体  $X$  的前  $k$  阶矩

$$\begin{aligned}\mu_l &= E(X^l) = \int_{-\infty}^{\infty} x^l f(x; \theta_1, \dots, \theta_k) dx \quad \text{or} \\ \mu_l &= E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \dots, \theta_k)\end{aligned}$$

其中  $R_X$  是  $X$  的取值范围，基于样本矩

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$$

依概率收敛于相应的总体矩  $\mu_l$ ，样本矩的连续函数依概率收敛于相应的总体矩的连续函数，我们就用样本矩作为相应的总体矩的估计量，而以样本矩的连续函数作为相应的总体矩的连续函数的估计量，这种估计方法称为 **矩估计法**。具体做法如下，设

$$\begin{cases} \mu_1 = \mu_1(\theta_1, \dots, \theta_k) \\ \mu_2 = \mu_2(\theta_1, \dots, \theta_k) \\ \vdots \\ \mu_k = \mu_k(\theta_1, \dots, \theta_k) \end{cases}$$

这是一个包含  $k$  个未知参数  $\theta_1, \dots, \theta_k$  的联立方程组，可解出

$$\begin{cases} \theta_1 = \theta_1(\mu_1, \dots, \mu_k) \\ \theta_2 = \theta_2(\mu_1, \dots, \mu_k) \\ \vdots \\ \theta_k = \theta_k(\mu_1, \dots, \mu_k) \end{cases}$$

以  $A_i$  分别代替上式中的  $\mu_i$ , 就以

$$\hat{\theta}_i = \theta_i(A_1, \dots, A_k)$$

分别作为  $\theta_i$  的估计量, 这种估计量称为 **矩估计量**, 矩估计量的观察值称为 **矩估计值**

**Example 7.1.** 设总体  $X$  在  $[a, b]$  上服从均匀分布,  $a, b$  未知,  $X_1, \dots, X_n$  是来自  $X$  的样本, 试求  $a, b$  的矩估计量

$$\mu_1 = E(X) = (a + b)/2$$

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = (b - a)^2/12 + (a + b)^2/4$$

解得

$$a = \mu_1 - \sqrt{3(\mu_2 - \mu_1^2)}, b = \mu_1 + \sqrt{3(\mu_2 - \mu_1^2)}$$

e 分别以  $A_1, A_2$  代替  $\mu_1, \mu_2$

**Example 7.2.** 设总体  $X$  的均值  $\mu$  及方差  $\sigma^2$  都存在, 且有  $\sigma^2 > 0$ , 但  $\mu, \sigma^2$  均未知, 又设  $X_1, \dots, X_n$  是来自  $X$  的样本, 试求  $\mu, \sigma^2$  的矩估计量

$$\begin{cases} \mu_1 = E(X) = \mu \\ \mu_2 = E(X^2) = \sigma^2 + \mu^2 \end{cases}$$

解得

$$\begin{cases} \mu = \mu_1 \\ \sigma^2 = \mu_2 - \mu_1^2 \end{cases}$$

因此

$$\hat{\mu} = A_1 = \bar{X}$$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

### 7.1.2 最大似然估计法

若总体  $X$  属于离散型, 其分布律  $P\{X = x\} = p(x; \theta), \theta \in \Theta$  的形式已知,  $\theta$  为待估参数,  $\Theta$  是  $\theta$  可能取值的范围, 设  $X_1, \dots, X_n$  是来自  $X$  的样本, 则  $X_1, \dots, X_n$  的联合分布

$$\prod_{i=1}^n p(x_i; \theta)$$

又设  $x_1, \dots, x_n$  是相应于  $X_1, \dots, X_n$  的样本值, 则事件  $\{X_1 = x_1, \dots, X_n = x_n\}$  发生的概率为

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \theta \in \Theta$$

$L(\theta)$  称为样本的 **似然函数**。取  $\hat{\theta}$  使

$$L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$$

这样得到的  $\hat{\theta}$  与样本值  $x_1, \dots, x_n$  有关, 常记为  $\hat{\theta}(x_1, \dots, x_n)$ , 称为参数  $\theta$  的 **最大似然估计值**, 而相应的统计量  $\hat{\theta}(X_1, \dots, X_n)$  称为参数  $\theta$  的 **最大似然估计量**

若总体  $X$  属连续型, 其概率密度  $f(x; \theta), \theta \in \Theta$  的形式已知, 设  $X_1, \dots, X_n$  是来自  $X$  的样本, 它们的联合密度为

$$\prod_{i=1}^n f(x_i; \theta)$$

设  $x_1, \dots, x_n$  是相应于样本  $X_1, \dots, X_n$  的一个样本值, 则随机点  $(X_1, \dots, X_n)$  落在点  $(x_1, \dots, x_n)$  的邻域 (变长分别为  $dx_1, \dots, dx_n$  的  $n$  维立方体) 内的概率近似地为

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$

因因子  $\prod_{i=1}^n dx_i$  不随  $\theta$  改变, 故只需考虑函数

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

的最大值, 这里  $L(\theta)$  称为样本的 **似然函数**, 若

$$L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$$

则称  $\hat{\theta}(x_1, \dots, x_n)$  为  $\theta$  的 **最大似然估计值**, 称  $\hat{\theta}(X_1, \dots, X_n)$  为  $\theta$  的 **最大似然估计量**

很多时候  $p(x; \theta), f(x; \theta)$  关于  $\theta$  可微, 因此  $\theta$  的最大似然估计可以从方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

求得, 这个方程称为 **对数似然方程**

**Example 7.3.** 设  $X \sim (1, p)$ ,  $X_1, \dots, X_n$  是来自  $X$  的一个样本, 求参数  $p$  的最大似然估计

设  $x_1, \dots, x_n$  是相应于样本  $X_1, \dots, X_n$  的一个样本值,  $X$  的分布律为

$$P\{X = x\} = p^x(1-p)^{1-x}, x = 0, 1$$

故

$$\begin{aligned} L(p) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \\ \ln L(p) &= \left(\sum_{i=1}^n x_i\right) \ln p + (n - \sum_{i=1}^n x_i) \ln(1-p) \\ \frac{d}{dp} \ln L(p) &= \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0 \\ \hat{p} &= \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \end{aligned}$$

**Example 7.4.** 设  $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma$  未知,  $x_1, \dots, x_n$  是来自  $X$  的一个样本值, 求  $\mu, \sigma^2$  的最大似然估计函数

$X$  的概率密度函数

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[ -\frac{1}{2\sigma^2} (x - \mu)^2 \right]$$



似然函数为

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left[ -\frac{1}{2\sigma^2} (x_i - \mu)^2 \right] \\ &= (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right] \\ \ln L &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned}$$

令

$$\begin{cases} \frac{\partial}{\partial \mu} \ln L = \frac{1}{\sigma^2} (\sum_{i=1}^n x_i - n\mu) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

解得

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

**Example 7.5.** 设总体  $X$  在  $[a, b]$  上服从均匀分布,  $a, b$  未知,  $x_1, \dots, x_n$  是一个样本值, 求  $a, b$  的最大似然估计函数记  $x_{(1)} = \min\{x_1, \dots, x_n\}$ ,  $x_{(n)} = \max\{x_1, \dots, x_n\}$ ,  $X$  的概率密度是

$$f(x; a, b) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{其他} \end{cases}$$

似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n} & a \leq x_1, \dots, x_n \leq b \\ 0 & \text{其他} \end{cases}$$

由于  $a \leq x_1, \dots, x_n \leq b$  等价于  $a \leq x_{(1)}, x_{(n)} \leq b$  似然函数可写成

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n} & a \leq x_{(1)}, b \geq x_{(n)} \\ 0 & \text{其他} \end{cases}$$

于是对于满足条件  $a \leq x_{(1)}, b \geq x_{(n)}$  的任意  $a, b$  有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

即  $L(a, b)$  在  $a = x_{(1)}, b = x_{(n)}$  时取得最大值, 故  $a, b$  的最大似然估计值为

$$\hat{a} = x_{(1)}, \hat{b} = x_{(n)}$$

此外, 最大似然估计具有下述性质: 设  $\theta$  的函数  $u = u(\theta), \theta \in \Theta$  具有单值反函数  $\theta = \theta(u), u \in \mathcal{U}$ , 又假设  $\hat{\theta}$  是  $X$  的概率分布中参数  $\theta$  的最大似然估计, 则  $\hat{u} = u(\hat{\theta})$  是  $u(\theta)$  的最大似然估计, 这一性质称为最大似然估计的**不变性**

## 7.2 基于截尾样本的最大似然估计

将随机抽取的  $n$  个产品在  $t = 0$  时投入试验直到每个产品都失效, 记录每一个产品的失效时间, 这样的道德样本叫完全样本。截尾寿命试验有两种: 定时截尾寿命试验, 假设将随机抽取的  $n$  个产品在  $t = 0$  投入试验, 试验进行到事先规定的截尾时间  $t_0$  停止, 如试验截止时共有  $m$  个产品失效, 它们的失效时间分别为

$$0 \leq t_1 \leq \dots \leq t_m \leq t_0$$

此时  $m$  是一个随机变量, 所得的样本  $t_1, \dots, t_m$  称为**定时截尾样本**。另一种是定数截尾样本,  $t_m$  是第  $m$  个产品的失效时间, 所得到的样本  $t_1 \dots t_m$  称为**定数截尾样本**

设产品的寿命分布为指数分布

$$f(t) = \begin{cases} \frac{1}{\theta} e^{-t/\theta} & t > 0 \\ 0 & t \leq 0 \end{cases}$$

设有  $n$  个产品投入定数截尾试验。一个产品在  $(t_i, t_i + dt_i]$  失效的概率近似地为  $f(t_i)dt_i = \frac{1}{\theta} e^{-t_i/\theta} dt_i$ , 其余  $n - m$  个产品寿命超过  $t_m$  的概率为  $(\int_{t_m}^{\infty} \frac{1}{\theta} e^{-t/\theta} dt)^{n-m} = (e^{-t_m/\theta})^{n-m}$ , 故上述观察结果出现的概率近似地为

$$\begin{aligned} & \binom{n}{m} \left( \frac{1}{\theta} e^{-t_1/\theta} dt_1 \right) \dots \left( \frac{1}{\theta} e^{-t_m/\theta} dt_m \right) (e^{-t_m/\theta})^{n-m} \\ &= \binom{n}{m} \frac{1}{\theta^m} e^{-\frac{1}{\theta}[t_1 + \dots + t_m + (n-m)t_m]} dt_1 \dots dt_m \end{aligned}$$

其中  $dt_1, \dots, dt_m$  为常数, 因忽略常数不影响  $\theta$  的最大似然估计, 故可取似然函数为

$$L(\theta) = \frac{1}{\theta^m} e^{-\frac{1}{\theta}[t_1 + \dots + t_m + (n-m)t_m]}$$

则

$$\frac{d}{d\theta} \ln L(\theta) = -\frac{m}{\theta} + \frac{1}{\theta^2} [t_1 + \dots + t_m + (n-m)t_m] = 0$$

于是

$$\hat{\theta} = \frac{s(t_m)}{m}$$

其中  $s(t_m) = t_1 + \dots + t_m + (n-m)t_m$  称为总试验时间

对于截尾样本

$$0 \leq t_1 \leq \dots \leq t_m \leq t_0$$

可得

$$L(\theta) = \frac{1}{\theta^m} e^{-\frac{1}{\theta}[t_1 + \dots + t_m + (n-m)t_0]}$$

$$\hat{\theta} = \frac{s(t_0)}{m}$$

其中  $s(t_0) = t_1 + \dots + t_m + (n-m)t_0$

### 7.3 评估量的评选标准

#### 7.3.1 无偏性

设  $X_1, \dots, X_n$  是总体  $X$  的一个样本,  $\theta \in \Theta$  是包含在总体  $X$  的分布中的待估参数, 这里  $\Theta$  是  $\theta$  的取值范围

**Definition 7.1.** 若估计量  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$  的数学期望  $E(\hat{\theta})$  存在, 且对于任意  $\theta \in \Theta$  有

$$E(\hat{\theta}) = \theta$$

则称  $\hat{\theta}$  是  $\theta$  的 **无偏估计量**

**Example 7.6.** 设总体  $X$  的  $k$  阶矩  $\mu_k = E(X^k)$  存在, 又设  $X_1, \dots, X_n$  是  $X$  的一个样本, 试证明不论总体服从什么分布,  $k$  阶样本矩  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  是  $k$  阶总体矩  $\mu_k$  的无偏估计

$X_1, \dots, X_n$  与  $X$  同分布, 故有

$$E(X_i^k) = E(X^k) = \mu_k$$

**Example 7.7.** 设总体  $X$  服从指数分布, 其概率密度为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

其中  $\theta > 0$  未知, 又设  $X_1, \dots, X_n$  是来自  $X$  的样本, 证明  $nZ = n(\min\{X_1, \dots, X_n\})$  是  $\theta$  的无偏估计

$Z = \min\{X_1, \dots, X_n\}$  具有概率密度

$$f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-nx/\theta} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

故

$$E(Z) = \frac{\theta}{n}$$

### 7.3.2 有效性

**Definition 7.2.** 设  $\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n), \hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$  都是  $\theta$  的无偏估计量, 若对于任意  $\theta \in \Theta$

$$D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$$

且至少对于某一个  $\theta \in \Theta$  上式不等号成立, 则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效

### 7.3.3 相合性

**Definition 7.3.** 设  $\hat{\theta}(X_1, \dots, X_n)$  为参数  $\theta$  的估计量, 若对于任意  $\theta \in \Theta$ , 当  $n \rightarrow \infty$  时  $\hat{\theta}(X_1, \dots, X_n)$  依概率收敛于  $\theta$ , 则称  $\hat{\theta}$  为  $\theta$  的相合估计量

## 7.4 区间估计

**Definition 7.4.** 设总体  $X$  的分布函数  $F(x; \theta)$  含有一个未知数  $\theta \in \Theta$ , 对于给定值  $\alpha (0 < \alpha < 1)$  若由来自  $X$  的样本  $X_1, \dots, X_n$  确定的两个统计量  $\underline{\theta} < \bar{\theta}$  对于任意  $\theta \in \Theta$  满足

$$P\{\underline{\theta}(X_1, \dots, X_n) < \theta < \bar{\theta}(X_1, \dots, X_n)\} \geq 1 - \alpha$$

则称随机区间  $(\underline{\theta}, \bar{\theta})$  是  $\theta$  的置信水平为  $1 - \alpha$  的 **置信区间**,  $\underline{\theta}, \bar{\theta}$  分别是双侧置信区间的 **置信下限**和 **置信上限**,  $1 - \alpha$  为 **置信水平**

**Example 7.8.** 设总体  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$  已知,  $\mu$  未知, 设  $X_1, \dots, X_n$  是来自  $X$  的样本, 求  $\mu$  的置信水平为  $1 - \alpha$  的置信区间

$\bar{X}$  是  $\mu$  的无偏估计, 且有

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

因此按正态分布

$$P\left\{\left|\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right| < z_{\alpha/2}\right\} = 1 - \alpha$$

即

$$P\left\{\bar{X} - \frac{\sigma}{\sqrt{n}}z_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}}z_{\alpha/2}\right\} = 1 - \alpha$$

因此得到了  $\mu$  的一个置信水平为  $1 - \alpha$  的置信区间

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}}z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}}z_{\alpha/2}\right)$$

寻求未知参数  $\theta$  的置信区间的做法

1. 寻求一个样本  $X_1, \dots, X_n$  和  $\theta$  的函数  $W = W(X_1, \dots, X_n; \theta)$  使得  $W$  的分布不依赖于  $\theta$  以及其他未知参数, 称具有这种性质的函数  $W$  为 **枢轴量**
2. 对于给定的置信水平  $1 - \alpha$  定出两个常数  $a, b$ , 使得

$$P\{a < W(X_1, \dots, X_n; \theta) < b\} = 1 - \alpha$$

## 7.5 正态总体均值与方差的区间估计

### 7.5.1 单个总体 $N(\mu, \sigma^2)$ 的情况

设已给定置信水平为  $1 - \alpha$ ，并设  $X_1, \dots, X_n$  为总体  $N(\mu, \sigma^2)$  的样本， $\bar{X}, S^2$  分别是样本均值和样本方差

#### 1. 均值 $\mu$ 的置信区间

(a)  $\sigma^2$  为已知，得到

$$\left( \bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$$

(b)  $\sigma^2$  未知，考虑  $S^2$  是  $\sigma^2$  的无偏估计，由定理 6.3

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

因此得  $\mu$  的一个置信水平为  $1 - \alpha$  的置信区间

$$\left( \bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$$

#### 2. 方差 $\sigma^2$ 的置信区间 $\mu$ 未知， $\sigma^2$ 的无偏估计为 $S^2$

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

有

$$P \left\{ \chi_{1-\alpha/2}^2(n-1) < \frac{(n-1)S^2}{\sigma^2} < \chi_{\alpha/2}^2(n-1) \right\} = 1 - \alpha$$

因此得到方差  $\sigma^2$  的一个置信水平为  $1 - \alpha$  的置信区间

$$\left( \frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right)$$

### 7.5.2 两个总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 的情况

设给定置信水平  $1 - \alpha$ ，并设  $X_1, \dots, X_{n_1}$  是来自第一个总体的样本； $Y_1, \dots, Y_{n_2}$  是来自第二个总体的样本，这两个样本相互独立，且设  $\bar{X}, \bar{Y}, S_1^2, S_2^2$  分别是第一、二个总体的样本均值、方差

1. 两个总体均值差  $\mu_1 - \mu_2$  的置信区间(a)  $\sigma_1^2, \sigma_2^2$  均为已知, 则

$$\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$$

因此得到  $\mu_1 - \mu_2$  的一个置信水平为  $1 - \alpha$  的置信区间

$$\left( \bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$$

(b)  $\sigma_1^2 = \sigma_2^2 = \sigma^2$ , 但  $\sigma^2$  未知, 此时由定理 6.4

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

可得  $\mu_1 - \mu_2$  的一个置信水平为  $1 - \alpha$  的置信区间为

$$\left( \bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right)$$

此处

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, S_w = \sqrt{S_w^2}$$

2. 两个总体方差比  $\sigma_1^2/\sigma_2^2$  的置信区间  $\mu_1, \mu_2$  均未知, 由定理 6.4

$$\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

有

$$P \left\{ F_{1-\alpha/2}(n_1 - 1, n_2 - 1) < \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} < F_{\alpha/2}(n_1 - 1, n_2 - 1) \right\} = 1 - \alpha$$

因此得  $\sigma_1^2/\sigma_2^2$  的一个置信水平为  $1 - \alpha$  的置信区间

$$\left( \frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right)$$

## 7.6 (0-1) 分布参数的区间估计

设有一容量  $n > 50$  的大样本, 它来自 (0-1) 分布的总体  $X$ ,  $X$  的分布律为

$$f(x; p) = p^x(1-p)^{1-x}, x = 0, 1$$

其中  $p$  为未知参数, 现在求  $p$  的置信水平为  $1 - \alpha$  的置信区间

已知 (0-1) 分布的均值和方差分别为

$$\mu = p, \sigma^2 = p(1-p)$$

设  $X_1, \dots, X_n$  是一个样本, 因样本容量  $n$  较大, 由中心极限定理, 知

$$\frac{n\bar{X} - np}{\sqrt{np(1-p)}} \sim N(0, 1)$$

于是有

$$P \left\{ -z_{\alpha/2} < \frac{n\bar{X} - np}{\sqrt{np(1-p)}} < z_{\alpha/2} \right\} \approx 1 - \alpha$$

而不等式

$$-z_{\alpha/2} < \frac{n\bar{X} - np}{\sqrt{np(1-p)}} < z_{\alpha/2}$$

等价于

$$(n + z_{\alpha/2}^2)p^2 - (2n\bar{X} + z_{\alpha/2}^2)p + n\bar{X}^2 < 0$$

记

$$p_1 = \frac{1}{2a}(-b - \sqrt{b^2 - 4ac})$$

$$p_2 = \frac{1}{2a}(-b + \sqrt{b^2 - 4ac})$$

此处  $a = n + z_{\alpha/2}^2, b = -(2n\bar{X} + z_{\alpha/2}^2), c = n\bar{X}^2$ , 于是得置信区间

$$(p_1, p_2)$$



## 7.7 单侧置信区间

对于给定值  $\alpha (0 < \alpha < 1)$  若由样本  $X_1, \dots, X_n$  确定的统计量  $\underline{\theta} = \underline{\theta}(X_1, \dots, X_n)$  对于任意  $\theta \in \Theta$  满足

$$P\{\theta > \underline{\theta}\} \geq 1 - \alpha$$

称随机区间  $(\underline{\theta}, \infty)$  是  $\theta$  的置信水平为  $1 - \alpha$  的 **单侧置信区间**,  $\underline{\theta}$  称为  $\theta$  的置信水平为  $1 - \alpha$  的单侧置信上限

若对于正态总体  $X$ , 若均值  $\mu$ , 方差  $\sigma^2$  均未知, 设  $X_1, \dots, X_n$  是一个样本, 由

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

有

$$P\left\{\frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{\alpha}(n-1)\right\} = 1 - \alpha$$

因此得到  $\mu$  的一个置信水平为  $1 - \alpha$  的单侧置信区间

$$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1), \infty\right)$$

## 8 假设检验

### 8.1 假设检验

**Example 8.1.** 某车间用一台包装机包装葡萄糖, 袋装糖的净重是一个随机变量, 它服从正态分布, 当机器正常时, 其均值为 0.5 kg, 标准差为 0.015kg, 某日开工后为检验包装机是否正常, 随机地抽取它所包装的糖 9 袋, 称得净重为 (kg)

0.497   0.506   0.518   0.524   0.498   0.511   0.520   0.515   0.512

问机器是否正常

以  $\mu, \sigma$  分别表示这一天袋装糖的净重总体  $X$  的均值和标准差。由于标准差比较稳定, 设  $\sigma = 0.015$ , 于是  $X \sim N(\mu, 0.015^2)$ , 这里  $\mu$  未知, 问题

是根据样本值来判断  $\mu$  是否等于 0.5。为此我们提出两个相互对立的假设

$$H_0 : \mu = \mu_0 = 0.5$$

$$H_1 : \mu \neq \mu_0$$

$\bar{X}$  是  $\mu$  的无偏估计,  $\bar{X}$  的观察值  $\bar{x}$  的大小在一定程度上反映  $\mu$  的大小。如果假设  $H_0$  为真, 则观察值  $\bar{x}$  与  $\mu_0$  的偏差  $|\bar{x} - \mu_0|$  一般不应太大

$P_{\mu_0}\{\cdot\}$  表示参数  $\mu$  取  $\mu_0$  时事件的概率,  $P_{\mu \in H_0}\{\cdot\}$  表示  $\mu$  取  $H_0$  规定的值时事件  $\{\cdot\}$  的概率。我们希望

$$P\{\text{当 } H_0 \text{ 为真拒绝 } H_0\} \leq \alpha$$

由于只允许犯这类错误的概率最大为  $\alpha$ , 因此

$$P_{\mu_0}\left\{\left|\bar{X} - \mu_0\right|\sigma/\sqrt{n} \geq k\right\} = \alpha$$

由于当  $H_0$  为真时,  $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ , 因此

$$k = a_{\alpha/2}$$

因此若  $Z$  的观察值满足

$$|z| = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \geq k = z_{\alpha/2}$$

则拒绝  $H_0$ , 反之接受

数  $\alpha$  称为 **显著水平**, 统计量  $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$  称为 **检验统计量**  
在显著水平  $\alpha$  下, 检验假设

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0$$

$H_0$  称为 **原假设**或 **零假设**,  $H_1$  称为 **备择假设**

当检验统计量取某个区域  $C$  中的值时, 我们拒绝原假设  $H_0$ , 则称区域  $C$  为 **拒绝域**, 拒绝域的边界点称为 **临界点**

$H_0$  为真时拒绝称为第 I 类错误,  $H_0$  不真时接收  $H_0$  称为第 II 类错误

只对犯第 I 类错误的概率加以控制而不考虑第 II 类错误的概率的检验称为 **显著性检验**。

$$H_0: \mu \leq \mu_0, \quad H_1: \mu > \mu_0$$

称为 **右边检验**

$$H_0: \mu \geq \mu_0, \quad H_1: \mu < \mu_0$$

称为 **左边检验**。左边检验和右边检验统称为 **单边检验**

设总体  $X \sim N(\mu, \sigma^2)$ ,  $\mu$  未知,  $\sigma$  已知,  $X_1, \dots, X_n$  是来自  $X$  的样本, 给定显著性水平  $\alpha$ , 求检验问题

$$H_0: \mu \leq \mu_0, \quad H_1: \mu > \mu_0$$

的拒绝域

因  $H_0$  中的全部  $\mu$  都比  $H_1$  中的  $\mu$  要小, 当  $H_1$  为真时, 观察值  $\bar{x}$  往往偏大, 因此拒绝域的形式为

$$\bar{x} \geq k$$

则

$$\begin{aligned} P_{\mu \in H_0} \bar{X} \geq k &= P_{\mu \leq \mu_0} \left\{ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq \frac{k - \mu_0}{\sigma/\sqrt{n}} \right\} \\ &\leq P_{\mu \leq \mu_0} \left\{ \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{k - \mu_0}{\sigma/\sqrt{n}} \right\} \end{aligned}$$

要控制  $P\{\text{当 } H_0 \text{ 为真拒绝 } H_0\} \leq \alpha$  只需令

$$P_{\mu \leq \mu_0} \left\{ \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{k - \mu_0}{\sigma/\sqrt{n}} \right\} = \alpha$$

因此  $\frac{k - \mu_0}{\sigma/\sqrt{n}} = z_\alpha, k = \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha$ , 即得拒绝域为

$$\bar{x} \geq \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha$$

同理得左边检验问题

$$H_0: \mu \geq \mu_0, \quad H_1: \mu < \mu_0$$

的拒绝域为

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \leq -z_\alpha$$

## 8.2 正态总体均值的假设检验